

UNIVERSITÉ CLAUDE BERNARD LYON 1
INSTITUT NATIONAL SUPÉRIEUR DU PROFESSORAT ET DE L'ÉDUCATION
ACADÉMIE DE LYON

MÉMOIRE DE MASTER 2

MÉTIERS DE L'ENSEIGNEMENT, DE L'ÉDUCATION ET DE LA FORMATION

Mention : Mathématiques

Responsable de la mention : CECCHINI Laurence (GAUTHIER Sébastien)

Responsable du parcours : GAUTHIER Sébastien

BIAIS DE NOTATION ET GRANDS MODÈLES DE LANGAGE

**RECHERCHES PRÉLIMINAIRE AUTOUR DE
L'IDENTIFICATION D'INFÉRENCES ÉLÈVES**

**Présenté par :
BALI Alexandre**

**Sous la direction de :
MERCAT Christian**

Examineurs :

MERCAT Christian

Année 2025-2026

N° d'étudiant : 11905404

Alexandre Bali

BIAIS DE NOTATION ET GRANDS MODÈLES DE LANGAGE : PREMIÈRES EXPLORATIONS AUTOUR DE L'IDENTIFICATION D'INFÉRENCES ÉLÈVES

64 Pages

Mémoire de master MEEF Mention Premier Degré/Second Degré

Université Claude Bernard Lyon 1 - INSPÉ - Université de Lyon

2025-2026

ABSTRACT / RÉSUMÉ

Dans le cadre de ce mémoire, nous étudions la pertinence de l'utilisation de grands modèles de langage (e.g. Llama, Mistral, Gemma, Deepseek...) pour identifier et noter les productions écrites d'élèves, en se concentrant autour de la question des inférences logiques. Nous nous intéressons aux grands modèles de langage sous un angle docimologique, l'objectif étant d'évaluer dans quelle mesure ces modèles peuvent contribuer à réduire les biais de notation dans une évaluation chiffrée, en commençant dans le contexte d'exercices de logique, en identifiant la prévalence de différentes inférences dans les productions d'élèves.

Nous montrons qu'au moins 37 % des modèles considérés (IC 95 %) ne sont pas atteints d'un biais de tendance centrale ($p < 0.05$), à savoir qu'ils dispersent les notes sans rester trop autour de la moyenne, et empiriquement plus de la moitié des modèles testés (14 sur 25). Cependant, ces modèles ont tendance à exacerber les écarts de notations inter-modèles par rapport à l'écart-type de 12 % régulièrement observé chez les correcteurs humains en mathématiques (IC 95 %), ce pour au moins la moitié des inférences analysées ($p < 0.05$).

MOTS-CLÉS

Docimologie

Intelligence artificielle

Logique mathématique

SOMMAIRE

AVANT-PROPOS ET REMERCIEMENTS.....	5
INTRODUCTION.....	6
1 PARTIE THÉORIQUE.....	8
1.1 Modèles de langage.....	8
1.1.1 Docimologie : biais de notations et premiers enjeux.....	8
1.1.2 Traitement automatique et modèles du langage.....	10
1.1.3 Grands modèles de langage.....	13
1.1.3.1 Mémoire.....	13
1.1.3.2 Écarts (température).....	14
1.1.3.3 Praticité.....	16
1.1.3.4 Avertissements notables.....	18
1.1.4 Conclusion.....	19
1.2 Noter les inférences.....	20
1.2.1 Inférences utilisées dans le secondaire.....	21
1.2.2 Notation de Fitch.....	22
1.2.3 Contra-classicismes.....	25
1.2.4 Adaptation au langage naturel.....	26
1.3 Conclusion et problématisation.....	28
2 MÉTHODOLOGIE.....	29
2.1 Modalités de l'expérience.....	29
2.1.1 Exercice central.....	29
2.1.2 Analyse a priori des inférences dans l'exercice donné.....	30
2.1.2.1 Question (a).....	31
2.1.2.2 Question (b).....	32
2.1.2.3 Question (c).....	32
2.1.2.4 Question (d).....	33
2.1.3 Recueil de données et modèles.....	34
2.2 Tests statistiques.....	37
2.2.1 Effet de tendance centrale, température fixée.....	37
2.2.2 Écarts de notation, température fixée.....	38
2.2.3 Choix et catégorisation des modèles, température et hardware utilisé.....	39
3 EXPÉRIMENTATION.....	41
3.1 Recueil de données et expérimentation.....	41
3.1.1 Déroulement et recueil des données élèves dans l'évaluation.....	41
3.1.2 Note moyenne, ou prévalences, de chaque inférence.....	42

3.1.3 Effet de tendance centrale.....	43
3.1.4 Écarts inter-modèles.....	44
3.1.5 Hallucinations.....	46
3.2 Conclusion de l'expérimentation.....	47
4 CONCLUSION.....	48
4.1 Qu'en tirer pour l'enseignant ?.....	50
4.2 Ouvertures pour la recherche.....	50
BIBLIOGRAPHIE.....	52
GLOSSAIRE.....	55
ANNEXES.....	56
Annexe A (Modèle de langage markovien).....	56
Annexe B (Distribution aléatoire, simulation de température).....	57
Annexe C (Page GitHub).....	58
Annexe D (Google Drive).....	59
Annexe E (Sujet complet du devoir surveillé).....	60
Annexe F (Questionnaire sur la portée de l'hypothèse).....	61
Annexe G (Exemple de traitement de copie d'élève).....	63
AUTORISATION DE DIFFUSION.....	64

AVANT-PROPOS ET REMERCIEMENTS

Au cours de mes expériences pédagogiques durant ma maîtrise en Métiers de l'Enseignement, de l'Éducation et de la Formation, mention mathématiques, j'ai constaté une utilisation croissante des intelligences artificielles génératives, notamment les grands modèles de langage (LLM) comme ChatGPT pour la résolution de problèmes, principalement de la part des étudiants. Cette observation, confirmée par les discussions avec mes collègues et les médias, soulève la question de l'intégration constructive de ces outils dans l'enseignement. Ce mémoire se propose d'examiner la pertinence des LLM dans l'analyse *a posteriori* de situations didactiques en mathématiques, visant à identifier les inférences mathématico-logiques employées par les élèves.

Je remercie notamment ma mère, mes amis dont mes collègues de master, et mon petit-ami pour m'avoir soutenu, motivé, et aidé pour l'aboutissement de ce master et de ce mémoire.

Je précise également que je ne soutiens pas spécialement l'utilisation des grands modèles de langage en dehors de considérations scientifiques, et plus spécifiquement linguistiques (e.g. sémantiques, sémiotiques), et autres pour lesquelles les modèles de langage ont originellement été conçus.

INTRODUCTION

Au cours des expériences pédagogiques auxquelles j'ai pris part durant ma maîtrise en Métiers de l'Enseignement, de l'Éducation et de la Formation, mention mathématiques, que ce soit lors de mon stage d'observation et de pratique accompagnée de M1, de mes permanences de tutorat en mathématiques, ou encore des séances que j'ai conduites en tutorat de mathématiques pour première année de licence Mathématiques-Informatique en parcours progressif, j'ai pu constater la croissance, sinon la prééminence, de l'utilisation des intelligences artificielles génératives, notamment les grands modèles de langage (*large language models*, LLM), principalement par le biais de l'agent conversationnel de la plateforme web *ChatGPT*, dans la résolution de problèmes. Les discussions que j'ai eues avec mon tuteur de stage et les autres professeurs de l'établissement, ainsi que les médias récents, corroborent cette tendance, aussi bien en mathématiques que dans les autres disciplines scolaires, suscitant des débats autour de leur place dans l'enseignement secondaire : ils mettent aussi bien en avant leur potentiel éducatif, qu'ils en dénoncent les usages à mauvais escient qu'en font les élèves pour tricher sur leurs devoirs et évaluations. Pour ne citer que quelques articles de presse :

- Diallo, K. (2024, juin 17). *"Je ne vois pas où est le problème": les enseignants divisés face à ChatGPT*. BFM.
- Pineau, C. (2024, octobre 23). *"C'est très efficace" : ce prof a une technique infaillible pour démasquer les devoirs faits avec ChatGPT*. Le Figaro.
- Rahmil, D.-J. (2024, juillet 10). *Lutter ou accompagner ? Le choix difficile des profs face à ChatGPT*. L'ADN.

Au cours de l'écriture de ce mémoire, le Ministère de l'Éducation nationale et de la Jeunesse a posé un cadre d'usage de l'IA en éducation, publié sur le site education.gouv.fr en juin 2025, presque un an après les premiers brouillons de ce mémoire – à un jour près. Face à cette réalité, la question de l'intégration de ces outils dans l'enseignement se pose alors. **Comment ces IA génératives peuvent être mobilisées de façon constructive en tant qu'enseignants des mathématiques ?** Dans ce mémoire, nous examinerons la pertinence des

LLM dans l'analyse *a posteriori* de situations didactiques que nous, enseignants de mathématiques, pouvons proposer aux élèves pour les conduire à employer des raisonnements mathématiques : devoirs surveillés, questions *flash*, exercices d'entraînement, etc.

En troisième année de licence, j'ai déjà pu étudier, pour mon rapport de stage en établissement, la mobilisation autonome du raisonnement par l'absurde chez des élèves de seconde. Cette thématique m'avait permis de mettre en lumière quelques procédures logiques employées par les élèves. J'ai donc décidé d'étendre cette réflexion en orientant ma recherche sur l'analyse des inférences élèves, en déterminant comment les grands modèles de langage pourraient être utilisés pour les identifier, et avec quels degrés d'incertitude. Ce travail vise ainsi à mieux juger de la pertinence de l'utilisation des IA génératives dans l'analyse *a posteriori* de situations didactiques dans l'enseignement des mathématiques. En d'autres termes, nous nous posons la question suivante : **les IA génératives peuvent-elles aider à identifier les inférences qu'emploient les élèves ?** Et surtout, afin de préserver un cadre scientifique, **comment juger de l'aide potentielle apportée par les IA génératives via des observables objectivables ?**

En particulier, dans un souci de précision de notre recherche, les IA génératives pourraient servir aux enseignants des mathématiques dans l'un de trois cas : après, pendant, ou avant une situation didactique. Dans l'*après*, nous pouvons notamment constater divers problèmes quant à l'analyse et la correction d'élèves, notamment lorsque l'on doit établir des valeurs numériques pour des évaluations telles que les devoirs surveillés. Nous pouvons alors nous demander **comment les IA génératives pourraient nous aider à établir des corrections plus objectives, et peut-être moins biaisées ?**

Je n'ai pas été exhaustif quant à toutes les questions que nous nous sommes posées vis-à-vis de l'utilisation des grands modèles de langage par les enseignants, mais cela nous donne déjà suffisamment de matière pour naviguer à travers moult lectures sur les sujets susmentionnés, et d'en tirer, nous l'espérons, une problématique digne de ce nom.

Notre plan va se poser en trois grandes parties : une partie théorique dans laquelle nous expliciterons des notions liées aux modèles de langage, munies de considérations

docimologiques qui nous conduiront vers l'étude spécifique des inférences logiques, afin de simplifier au mieux la partie expérimentale ; cette partie expérimentale sera d'ailleurs expliquée en deux grandes parties, d'une part une analyse *a priori*, d'autre part les résultats et analyse *a posteriori* de l'expérimentation.

Pour répondre à la problématique que nous allons formuler en fin de la partie théorique, nous établirons une analyse *a priori* d'inférences observables chez les élèves, et nous demanderons aux grands modèles de langage mobilisés de générer des pourcentages de concordance, entre les propositions-élèves obtenues *a posteriori*, et chaque étape possible identifiée dans l'analyse *a priori* ; il s'agira donc de comparer les modèles, via un exercice de *multi-correction* (Merle, 2018), procédé hérité de la docimologie...

1 PARTIE THÉORIQUE

1.1 Modèles de langage

1.1.1 Docimologie : biais de notations et premiers enjeux

La docimologie est définie comme la « science des examens et des concours, étude de la qualité et de la validité des différents systèmes de notation scolaire et de contrôle des connaissances » par le Trésor de la Langue Française informatisé (TLFi) du Centre National de Ressources Textuelles et Lexicales (CNRTL).

Demander à avoir une phrase ou une approximation suffisamment similaire d'être présente sur la copie fait partie intégrante de la correction d'élèves, tout particulièrement en mathématiques. Dans un document du Groupe Académie d'Animation en Mathématiques (2009), on peut par exemple voir dans divers barèmes des indicateurs de réussite, tels que « Écrire l'égalité : $BC^2 = AB^2 + AC^2$ », « Les mots Pythagore et triangle rectangle sont cités ». Ainsi, la notation quantitative et graduée de phrases types, y compris des étapes d'une inférence, sur leur degré de présence ou non dans une copie d'élève, constitue tout à fait un sujet d'étude docimologique et, de fait, sujette aux mêmes biais. Lecoix (2019) présente une liste de biais courants identifiés en docimologie, conduisant les notes à être attribuées aux productions d'élèves selon des informations extrinsèques à leur seul contenu :

- L'effet de *relativation*, qui mène le professeur à attribuer des notes en fonction des notes du groupe.
- La *constante macabre* (Antibi, 1988), qui conduit le professeur à établir un pourcentage constant de mauvaises notes à chaque évaluation notée, peu importe le niveau réel des productions.
- L'effet de contraste, où chaque copie influence l'évaluation de la suivante.
- L'effet de stéréotypie, duquel l'enseignant attribue des notes constamment similaires à un élève, quel que soit l'effort réel fourni.
- L'effet de halo, pour lequel la présentation de l'élève, ou de sa production, influence sa note, indépendamment de la qualité du contenu produit.
- L'effet de tendance centrale, qui conduit le professeur à concentrer ses notes autour de la moyenne.
- Lecoix (2019) relate également qu'à une même copie, pourtant avec un barème précis, les notes qui lui sont attribuées peuvent être sujettes à des écarts importants. Nous parlerons simplement d'effet d'écart de notation.
- Enfin, la loi de Posthumus décrit comment les enseignants attribuent les notes en se basant sur une loi normale (Gaussienne), ce qu'on peut relier à la *constante macabre* (« 13% de médiocres ; [...] 2% de mauvais (cancres) »), voire à l'effet de tendance centrale.

Nombre de ces biais ont en commun qu'ils rendent la notation mnémonique : ils la rendent dépendante de productions récentes, qu'elles soient de l'élève lui-même (stéréotypie) ou de ses camarades (*relativation*, contraste). Nous pouvons alors supposer qu'un traitement sans mémoire, si possible, devrait atténuer ces biais-ci.

Une première idée de mitigation possible serait alors de corriger chaque copie par un correcteur différent, n'étant donné que le seul contenu de sa production, si possible tapé à l'ordinateur pour également éviter l'effet de halo. Toutefois, même en supposant la praticité d'un tel dispositif, il subsiste aussi des biais qui portent davantage de la variation individuelle : il s'agit là des effets liés à la loi de Posthumus (effet de tendance centrale, *constante macabre*) et d'écart de notation.

Nous posons alors les *desiderata* suivants pour le traitement des notes :

- I. Un traitement sans mémoire : l'évaluation de la production ne dépend que de son contenu, et non d'informations récentes.
- II. Un traitement qui atténue les biais de distribution du correcteur :
 - A. Plusieurs corrections d'une même production, à partir de ce seul traitement, doivent amener à un écart significativement moindre que l'écart *humain*.
 - B. Ce traitement ne suit pas nécessairement la loi de Posthumus. Pour vérifier cela, nous pourrions procéder par *modus tollens* en constatant, par exemple, que ce traitement peut donner des moyennes significativement différentes de 50 %, sinon quoi il serait atteint d'effet de tendance centrale, conséquence de la loi de Posthumus.
- III. Un traitement pratique pour les enseignants : une explication précise de sa mise en œuvre doit être donnée, afin d'aider les enseignants à s'approprier l'outil de traitement avec de moindres difficultés.

Nous allons alors explorer le monde du traitement automatique du langage, de sorte d'apporter des premiers éléments de réponse, dans l'optique d'expliquer la pertinence des grands modèles de langage dans cette tâche.

1.1.2 Traitement automatique et modèles du langage

Un modèle de langage, selon Hiemstra (2009) :

“assigns a probability to a piece of [...] text, based on some training data. For example, a language model based on a big English newspaper archive is expected to assign a higher probability to “a bit of text” than to “aw pit tov tags,” because the words in the former phrase [...] occur more frequently in the data than the words in the latter phrase.”

[« assigne des probabilités à des bouts de texte [...], basés sur des données d'entraînement. Par exemple, un modèle de langage entraîné sur un répertoire d'archives d'un journal anglais conséquent devrait assigner une probabilité plus grande à « un bout de texte » qu'à « ain but deux taxes », car les mots dans la première

expression [...] apparaissent plus fréquemment dans les données que les mots de la dernière expression. »]

Ainsi, il est possible de construire des modèles de langage, et de nombreux outils de traitement automatique du langage, aussi simplistes ou complexes que l'on souhaite, formels ou non (e.g. DisCoCat, BERT, SquAD...).

Les modèles markoviens du langage font partie des plus anciens ; par exemple, le linguiste Noam Chomsky en parlait déjà en 1956. Selon Langville & Hilgers (2006) :

“Chomsky argued that language models based on Markov chains do not capture some nested structures of sentences, which are quite common in many languages such as English. We now recognize that Chomsky's account of the limitations of Markovian language models was too harsh. The early 1980s saw a resurgence of the success of Markovian language models in speech recognition.”

[« Chomsky défendait que les modèles de langage basés sur les chaînes de Markov ne capturent pas certaines structures d'imbrication phrastiques, qui sont assez courantes dans bien des langues telles que l'anglais. On sait désormais que le rapport de Chomsky sur les limitations des modèles de langage markoviens était trop sévère. Le début des années 1980 vit un regain du succès des modèles de langage markoviens dans la reconnaissance vocale. »]

Par la pertinence historique de l'utilisation des chaînes de Markov dans les modèles de langage (et son utilisation toujours actuelle, par ailleurs), nous étudierons d'abord les résultats d'un modèle de langage markovien, dont nous avons mis le code dans l'[Annexe A](#), pour dégager quelques *desiderata* supplémentaires.

Ce programme permet de générer procéduralement des mots et ponctuations à partir des diverses variables d'entrée du programme. La variable `text` sert de données textuelles d'entraînement, qui sont ensuite segmentées en une séquence de mots et de ponctuations, qui deviennent les états de notre chaîne de Markov, les probabilités assignées à chaque transition suivant la distribution empirique obtenue par cette segmentation de `text`. La variable `prompt`, quant à elle, donne l'état de départ pour le texte qu'il génère : celui-ci doit

être présent dans les données d'entraînement. Une fois cela fait, le modèle génère un texte de `n` tels états, séparés par des espaces dans le retour du programme, en suivant les états et probabilités des transitions générées par `text`.

En prenant `text` une ancienne version du texte d'introduction de ce mémoire, converti en minuscules et sans sauts à la ligne, et en lui donnant également pour `prompt` la chaîne de caractères "`la`", et pour `n` la valeur 50, on peut obtenir la sortie suivante :

```
la résolution de problèmes . comment ces outils dans les
conduire à mauvais escient qu ' utilisation des réponses et de
tutorat de seconde . en tant qu ' absurde chez des llm ) ,
pour première année de l ' enseignants de façon constructive
en dénoncent les élèves pour les
```

On peut d'emblée repérer divers points susceptibles d'être améliorés. D'une part, bien que le programme soit bien construit pour s'assurer que les paires de deux états consécutifs soient en succession réaliste, les séquences de trois états ou plus peuvent déjà donner lieu à des incohérences linguistiques, comme les exemples de « l'enseignants » [sic] (où « l », « ' » et « enseignants » sont trois états distincts), ou encore « dans les conduire » [sic]. De plus, par la spécificité et la faible taille du texte d'entraînement, le vocabulaire disponible dans les états de la chaîne de Markov engendrée par sa segmentation est fortement limité, à peine plus de 200 mots uniques. Enfin, pour revenir à ce que nous disions précédemment, le fonctionnement du programme est très limité sur le plan des paramètres capables d'être manipulés. Tout cela mène à des limitations telles qu'avoir pour `prompt` un des états spécifiques de la chaîne de Markov engendrée par le texte d'entraînement, là où l'on pourrait s'attendre à ce que l'utilisateur souhaite converser avec une phrase, qu'il emploie des néologismes, ou qu'il s'exprime dans des langues omises par le programme.

Ainsi, nous voudrions énoncer des *desiderata* supplémentaires :

- I. Une prise en compte de la grammaire et du contexte syntaxique.
- II. Un vocabulaire riche.
- III. Une prise en charge de textes d'entrée plus riches (e.g. phrases, néologismes).
- IV. Une prise en compte du contexte sémantique.

1.1.3 Grands modèles de langage

Un grand modèle de langage est caractérisé ainsi dans Minaee et al. (2024, p. 1-2) :

“Large language models (LLMs) mainly refer to transformer-based neural language models that contain tens to hundreds of billions of parameters, which are pre trained on massive text data, such as PaLM, LLaMA, and GPT-4, [...]. [...] LLMs are not only much larger in model size, but also exhibit stronger language understanding and generation abilities, and more importantly, emergent abilities that are not present in smaller-scale language models.”

[« Les grands modèles de langage (LLM) sont principalement les modèles de langage neuronaux à couches transformatrices qui contiennent de dizaines à centaines de milliards de paramètres, lesquels sont entraînés au préalable sur des données textuelles massives, comme pour PaLM, LLaMA, et GPT-4, [...]. [...] Les LLM ont non seulement une taille de modèle plus grande, mais manifestent aussi de plus fortes compréhension et capacités de génération du langage, ainsi que, plus notoirement encore, des capacités émergentes qui ne sont pas présentes dans des modèles de langage plus réduits. »]

Grâce à cela, le vocabulaire est largement enrichi, la compréhension du langage est accrue, dont la prise en compte de la grammaire et du contexte, aussi bien sur le plan syntaxique que sémantique. Qui plus est, les agents conversationnels basés sur des grands modèles de langage, tels que ChatGPT, sont capables de générer du texte à partir d'un texte d'entrée riche, qu'on appelle habituellement un *prompt*. De la sorte, les grands modèles de langage permettent de satisfaire les *desiderata* identifiés dans la section de présentation des modèles du langage.

Nous allons désormais explorer plus en profondeur comment les grands modèles de langages peuvent remplir les *desiderata* présentés dans la section sur les biais de notation.

1.1.3.1 Mémoire

Un *token* étant une représentation d'éléments textuels, permettant au modèle de prendre en charge et de générer du texte à partir de petits éléments de texte. Les grands modèles de langage sont dotés d'une fenêtre contextuelle, aussi appelé *contexte*, d'unité *token*, qui est

précisément le nombre de *tokens* duquel le modèle paramétré peut prendre en charge. Tout *token* en dehors de la fenêtre contextuelle n'est alors pas pris en compte.

Sur [GPT-5 Chat](#), une fenêtre contextuelle de tchat est de 128 000 *tokens*. Sur Google AI Studio, un agent conversationnel basé sur la famille de modèles Gemini, un tchat ne peut pas dépasser 1 048 576 *tokens*. Pour donner un dernier exemple, le package Python `ollama` permet à l'utilisateur de choisir le nombre de *tokens* constituant la fenêtre contextuelle du modèle choisi, grâce au paramètre `num_ctx`.

Si Ollama permet de contrôler la fenêtre contextuelle, chaque génération est de toute manière indépendante les unes des autres. Quant à ChatGPT, un tchat peut être toutefois composé de blocs *prompts*-générations successifs qui se rappellent des précédents. De plus, on peut également contrôler la mémoire entre les tchats, de sorte que tous les tchats sur un même compte se basent les uns sur les autres, jusqu'à épuisement de la fenêtre contextuelle.

En conclusion, les différents modèles et agents conversationnels associés sont capables de contrôler la mémoire de façon assez fine, ce qui nous permettra de générer des évaluations complètement indépendantes les unes des autres.

1.1.3.2 Écarts (température)

Nous pouvons imaginer que cela puisse être lié à l'hyper-paramètre de *température*. Selon Peeperkorn et al. (2024) :

“The temperature parameter of an LLM regulates the amount of randomness, leading to more diverse outputs; therefore, it is often claimed to be the creativity parameter.” (p. 1) “Temperature is a hyperparameter t that we find in stochastic models to regulate the [distribution of] a sampling process[,] [...] its [distribution's] shape, redistributing the output probability mass, flattening the distribution proportional to the chosen temperature.” (p. 3) “We [...] observe a [...] moderately negative correlation between coherence and temperature” (p. 8)

[« Le réglage température d'un LLM régule le seuil d'aléa, conduisant à des résultats plus variés ; ainsi, on affirme souvent qu'il s'agit du réglage de créativité. » (p. 1) « La

température est un hyper-paramètre t , présent dans les modèles stochastiques pour réguler la loi de probabilité d'un échantillonnage, redistribuant la fonction de masse résultante, de sorte à aplatir la loi proportionnellement à la température choisie. » (p. 3) « On [...] observe une [...] corrélation modérément négative entre cohérence et température. » (p. 8)]

En d'autres termes, plus la température est grande, plus les probabilités de sortie sont homogènes, ce qui conduit à davantage de variété, mais aussi d'incohérence dans les réponses générées par le modèle. Ainsi, si l'on veut s'assurer que les résultats varient le moins possible, il vaut mieux avoir une petite température. Rochlin (2024) nous informe que celle de ChatGPT est par défaut autour de 0.7, mais peut varier de 0.0 à 1.0 selon ce que désire l'utilisateur – à noter qu'en général, la température varie sur $\mathbf{R}^+$.




Figure 1. Exemple d'une distribution de probabilité discrète en points noirs, des distributions obtenues par application de l'hyper-paramètre température $\theta \in \{e^{-7} ; e^{-2} ; e^1\}$ sur celle-ci en points rouges – dont leurs interpolations affines par morceaux respectives, afin d'améliorer la lisibilité des graphiques. ([Desmos](#))

En utilisant des distributions aléatoires de notes comme dans la figure 1, on peut simuler une couche de température sur cette distribution à températures variées, grâce à la fonction *softmax*, que l'on peut retrouver développée dans Peeperkorn et al. (2024) et Weinmeister (2024), pour déterminer l'impact de la température sur l'écart-type. On doit s'attendre à ce que, lorsque la température tend vers 0, l'écart-type tende vers 0, ce qui est effectivement ce que l'on remarque dans la figure suivante :




Figure 2. Écart-type de la distribution obtenue par application de softmax à température θ à la distribution de X , selon la température, sur dix distributions aléatoires, de 5 (rouge) à 50 (bleu) notes possibles chacune. (voir [Annexe B](#) pour code précis)

À noter que malgré cette tendance, la température semble parfois admettre un maximum, plus ou moins proche de zéro, selon le support de notre distribution. Nous pouvons donc établir qu'il y a un lien entre la température et les écarts des notations, bien que le lien entre écart-type et température n'est pas nécessairement monotone.

1.1.3.3 Praticité

Les plateformes en ligne d'agents conversationnels à grands modèles de langage, telles ChatGPT et Google AI Studio, sont dotées d'une interface utilisateur permettant de directement poser un *prompt* désiré. Ce dernier permet aussi de contrôler la température entre 0 et 2, mais ni l'un ni l'autre ne permet de contrôler la fenêtre contextuelle.

Ollama est quant à lui plus permissif, mais demande des connaissances programmatiques plus avancées pour pouvoir le manipuler, puisqu'il ne possède pas de GUI par défaut et se

contrôle sur le terminal de commandes et/ou via Python. Nous pouvons toutefois expliquer comment l'utiliser dans les grandes lignes.

Pour utiliser Ollama tout seul, on peut suivre ces instructions :

- Il faut tout d'abord installer Ollama via <https://ollama.com/>
- Pour installer ou interroger un modèle, on peut entrer `ollama run modelName` dans le terminal de commandes.

Si l'on veut interroger les modèles sur Ollama via Python :

- Il faut installer Python via <https://www.python.org/downloads/>
- Une fois cela fait, il suffit d'ouvrir le terminal de commandes et d'entrer `py -m pip install` sur Windows, ou `python -m pip install` sur Linux et Mac.
- On peut ensuite copier-coller ce code Python dans un fichier d'extension `.py` :

```
"""paramètres"""
modele = "llama3.1:8b"
# changer modèle
prompt = "Qui était le 32ème président des États-Unis ?"
# changer prompt ici
temperature = 0.5
# changer température
seuil_max_tokens_generables = 4096
# changer seuil max de tokens générables

"""partie code"""
import ollama
string = ''
stream = ollama.chat (
    model = modele,
    messages = [
        {"role" : "user",
         "content" : prompt}
    ],
    stream = True,
    options = {
        "temperature" : temperature,
        "num_predict" : seuil_max_tokens_generables,
    })
for chunk in stream :
    print(chunk["message"]["content"], end = '')
```

Le Ministère de l'Éducation nationale et de la Jeunesse (2025) a toutefois établi un cadre d'usage des grands modèles de langage (et l'IA plus généralement) en éducation, qui comprend principalement le respect du cadre légal sur la protection des données à caractère personnel (norme RGPD). Surtout : « le recours aux services d'IA accessibles au grand public est autorisé sous réserve qu'aucune donnée confidentielle ou à caractère personnel ne soit utilisée : ne peuvent ainsi être saisies dans de tels outils que des données qui peuvent être rendues publiques (notamment : textes et programmes officiels, ressources éducatives libres, données statistiques anonymisées, œuvres du domaine public). »

En-dehors des seules considérations de la recherche dans ce mémoire, les enseignants ont une obligation de transparence s'ils utilisent l'IA dans un processus de décision éducative, pédagogique ou administrative : non seulement « toute décision prise à l'aide d'une IA à partir de données personnelles doit faire l'objet d'une information auprès des personnes concernées, en leur expliquant leurs droits et en leur permettant d'agir en cas de désaccord », mais « toute décision s'appuyant sur l'IA, ayant un impact significatif sur l'évaluation des apprentissages, les parcours des élèves ou les parcours professionnels, doit faire l'objet [...] d'une supervision humaine garantissant son usage équitable et son explicabilité [et] d'une validation préalable par l'autorité compétente. » Diverses recommandations éthiques et déontologiques y sont également indiquées : nous invitons ainsi tout professeur intéressé par le contenu de ce mémoire à se référer à cet article du Ministère de l'Éducation nationale et de la Jeunesse (2025) pour plus d'informations.

1.1.3.4 Avertissements notables

Bien que les grands modèles de langage semblent prometteurs pour satisfaire nombre des *desiderata* identifiés jusqu'alors, le Ministère de l'Éducation nationale et de la Jeunesse (2025) nous met toutefois en garde sur certains aspects qui peuvent impacter la crédibilité et la pertinence de ces modèles sur la notation. Notamment, ceux-ci indiquent la présence de « biais et risques de reproduction, voire d'amplification des stéréotypes et discriminations », et de « risques d'inexactitudes, voire de réponses fausses (‹ hallucinations ›) ».

Il sera difficile de vérifier la présence d'hallucinations si nous restreignons trop le format des sorties, tel que nous pourrions le faire en utilisant ce qu'on appelle du *structured output* [« sortie structurée »], que nous pouvons faire, par exemple, en étendant la classe `BaseModel` de `pydantic`, et sa méthode `model_json_schema`, pour donner un format JSON spécifique à un modèle de Ollama par exemple via le paramètre `format` (Ollama, 2024), ou en créant extension de `BaseModel` pour formater les réponses selon un type spécifique. Nous essaierons alors, lorsque nous exposerons la méthodologie, de permettre une plus grande variété de formats possibles, et d'en extraire le premier pourcentage ou nombre énoncé – s'il y en a un, sinon nous retournerons un `nan`.

1.1.4 Conclusion

Nous pouvons nous attendre que les grands modèles de langage permettent, semble-t-il, de satisfaire la plupart des *desiderata* avancés jusqu'ici, à savoir :

- 1) En termes de traitement de la notation :
 - a) Un traitement sans mémoire : l'évaluation de la production ne dépend que de son contenu, et non d'informations antérieures. Toutefois, dans le cas de l'utilisation d'un agent conversationnel en ligne, cela demande soit un contexte suffisamment petit, soit en prenant soin d'avoir des conversations différentes, en prenant soin de désactiver la mémoire inter-conversations.
 - b) Plusieurs corrections d'une même production, à partir de ce seul traitement, doivent amener à un écart significativement moindre (effet d'écart de notation) : la température aide effectivement à cela, notamment à température très petite, voire nulle.
 - c) Un traitement pratique pour les enseignants : une explication précise de sa mise en œuvre a pu être donnée, afin d'aider les enseignants à s'approprier l'outil de traitement avec de moindres difficultés.
- 2) En termes de traitement du langage :
 - a) Une prise en compte de la grammaire et du contexte syntaxique.
 - b) Un vocabulaire riche.
 - c) Une prise en charge de textes d'entrée plus riches (e.g. phrases, néologismes).

d) Une prise en compte du contexte sémantique.

Toutefois, il subsiste des points de vigilance :

- Il reste encore à montrer que ces modèles n'admettent pas d'effet de tendance centrale.
- À température égale, nous ne savons pas non plus si des modèles de langage différents concordent effectivement sur leurs notations.
- Enfin, étant donné que la température n'est pas tout à fait accessible directement sur toutes les plateformes (notamment ChatGPT), nous pourrions nous demander si une température égale à la température par défaut de ChatGPT, de 0.7, serait nécessairement suffisante pour assurer un écart moindre que l'écart observable chez les correcteurs humains.

Afin de tester cela, et que l'on établisse des comparaisons pertinentes entre correcteurs humains et grands modèles de langage, nous établirons un barème précis sur des éléments d'évaluation. Pour rendre le barème aussi pointu que possible, nous nous concentrerons sur l'identification et la notation d'inférences. Nous nous concentrerons sur le cas de la température nulle. Si les résultats sont probants, nous pourrions ainsi motiver de futures recherches autour de températures strictement positives (e.g. 0.7).

1.2 Noter les inférences

Dans ce mémoire, nous nous baserons sur la définition d'inférences donnée par Françoise Armengaud (*Encyclopædia Universalis*), une inférence est une procédure :

« qui passe de propositions assertives, comme prémisses, à des propositions assertives, comme conclusions. Au sens strict, on distingue l'inférence du raisonnement en ce qu'elle peut être soit médiate soit immédiate [...] tandis que le raisonnement comporte nécessairement des médiations (il est discursif). On distingue aussi l'inférence démonstrative ou déduction [...] et l'inférence non démonstrative [...]. L'inférence déductive est qualifiée de valide ou de non valide ; cette qualification ne se retrouve pas exactement [autrement] [...]. L'inférence valide s'effectue conformément à

des règles qui permettent de déduire d'un ensemble de prémisses toutes les conséquences logiques et elles seulement. » (Armengaud, 2006)

Ainsi, une inférence n'est pas nécessairement valide, elle peut même être non déductive, – par exemple, inductive ou abductive (Eduscol, 2019a), – et ne même pas être explicitée par l'élève. En outre, nous en tirons également qu'un raisonnement n'est autre qu'une inférence médiate.

La concentration sur la notion d'inférence est en continuation directe avec mes premières expériences de classe en troisième année de licence, dans lesquelles étaient établis divers tests statistiques inférentiels pour attester de l'utilisation d'inférences liées à la négation. L'expérience était assez simpliste, l'exercice aussi. Pour ce mémoire, nous chercherons alors à aller plus loin, en se basant sur des travaux de recherche pour établir l'exercice-phare de notre étude, qui nécessitera sans doute des analyses beaucoup plus fines.

1.2.1 Inférences utilisées dans le secondaire

Hormis les procédures personnelles des élèves, divers raisonnements sont utilisés dans le secondaire, que l'on retrouve notamment dans Eduscol (2016; 2019a; 2019b) et autres :

- Les raisonnements par l'absurde :
 - a. l'un consistant à prouver la négation d'une proposition en supposant qu'elle soit démontrable, et en déduisant une contradiction (telle P , mais non- P).
 - b. un autre consistant à prouver qu'une proposition est démontrable en supposant que sa négation le soit, et en déduisant une contradiction.
- Les raisonnements par disjonction de cas :
 - a. Si l'on peut démontrer soit P soit Q , et qu'une proposition R est déductible de P comme de Q , on en conclut R , indépendamment de P ou Q .
 - b. Si une proposition R est déductible de P comme de la négation de P , on en conclut R , indépendamment de P ou Q .
 - c. Si l'on peut démontrer soit P soit Q soit les deux, et qu'une proposition R est déductible de P comme de Q , on en conclut R , indépendamment de P ou Q .
- Le raisonnement direct : Si P , alors Q . Or, P . Donc, Q .

- Le raisonnement par double implication : Pour montrer que P équivaut à Q , on montre d'abord que si P alors Q , puis, que si Q alors P .
- Le raisonnement par équivalence : Pour montrer que P équivaut à Q , on établit une famille de propositions $P_1, P_2, \dots, P_n$ telles que P équivaut à P_1 , que P_n équivaut à Q , et que P_i équivaut à P_{i+1} pour tout entier i entre 1 et $n-1$ compris.

Dans ces brochures, ces raisonnements sont explicités dans un registre langagier : par exemple, le raisonnement par l'absurde dans Eduscol (2019b, p. 28) est décrit ainsi : « Pour démontrer une proposition P , on suppose que sa négation (non P) est vraie, on en déduit des conséquences qui aboutissent à une contradiction. Cela montre que (non P) ne peut pas être vraie, et par conséquent que P est vraie ».

Cependant, dans le domaine de la logique mathématique, qui étudie précisément ces inférences, celles-ci sont souvent exprimées très différemment, principalement via la notion de règles d'inférence. Nous allons tenter d'intégrer quelques apports de la logique mathématique pour nous aider à mieux formaliser cette notion d'inférence.

1.2.2 Notation de Fitch

Les opérations et inférences utilisées en mathématiques scolaires proviennent de la logique formelle classique. Or, selon Gao (2017, p. 19), “proof is syntactic” [« une preuve est syntaxique »] en logique classique ; dans ce contexte, une preuve :

- commence avec une collection de prémisses,
- transforme ces prémisses selon une collection de règles d'inférence (via filtrage par motif),
- parviennent alors à une conclusion.

Cela rejoint effectivement la définition de ce qu'est une inférence donnée par Armengaud (2006). Cette idée de “pattern matching” [« filtrage par motif »] rejoint quant à elle l'idée que certaines propositions suivent un schéma spécifique. Cette approche syntaxique fonde le champ de la déduction naturelle, utilisée dans Gao (2017), mais mise plus particulièrement en exergue dans Magnus et al. (2025). Ces approches tendent à utiliser des connecteurs logiques dans un registre symbolique plutôt que langagier ($\wedge, \vee, \Rightarrow, \Leftrightarrow, \neg$).

Parmi ces symboles, $\Leftrightarrow$, tout particulièrement, peut être présent dans certains manuels, comme *Math'x Seconde* (2010, p.351), ainsi que dans *Décllic 2nde* (2010, p.329) (Grenier et al., 2019, p. 11).

Magnus et al. (2025) nous servira de guide principal pour adopter une formalisation plus usuelle et systématique des schémas inférentiels. Celui-ci utilise ce qu'on appelle la notation de Fitch pour les preuves, qui est construite de la sorte :

- On pose initialement trois colonnes, où sont délimitées la première et la deuxième l'une de l'autre par une ligne verticale :
 - Celle de gauche est composée d'entiers, en partant de 1, qui incrémentent d'une ligne à la suivante, permettant d'expliciter le numéro de chaque étape de la preuve.
 - Celle du milieu est composée des propositions, qu'elles soient justifiées ou admises.
 - Celle de droite, qui explicitent la justification utilisée, souvent avec des initiales ou une abréviation symbolique d'un côté, et de l'autre les numéros des étapes utilisées, conjointes par des virgules.
- Chaque hypothèse ajoutée, au-delà des conditions initiales, crée une nouvelle indentation délimitée par une ligne verticale à droite, ainsi qu'un trait horizontal en dessous de l'hypothèse pour spécifier qu'il s'en agit d'une ; on parle alors de la sous-preuve associée à la proposition érigée en supposition.
- Chaque sous-preuve peut n'être citée, dans la colonne de droite, qu'à la couche précédente en termes d'imbrication de sous-preuves. En posant i la ligne sur laquelle se trouve l'hypothèse, et j une proposition sous cette hypothèse supplémentaire, et surtout, sans hypothèses supplémentaires, alors on citera ce bloc comme $i-j$.
- Chaque citation dans la colonne de droite doit faire appel uniquement aux lignes dans la même sous-preuve, ou dans les sous-preuves où elle se trouve imbriquée.

Par exemple, voici une démonstration du syllogisme hypothétique (transitivité de l'implication) :

1	$A \rightarrow B$	
2	$B \rightarrow C$	
3	A	
4	B	$\rightarrow E$ 1, 3
5	C	$\rightarrow E$ 2, 4
6	$A \rightarrow C$	$\rightarrow I$ 3–5

Dans Magnus et al. (2025), on résume le séquent (théorème) démontré ici en juxtaposant les hypothèses initiales par des virgules, puis avec la conclusion avec $\therefore$ ou $\vdash$ entre les deux, ce qui donne « $A \rightarrow B, B \rightarrow C \therefore A \rightarrow C$ » ou « $A \rightarrow B, B \rightarrow C \vdash A \rightarrow C$ ».

On retrouve de nombreuses inférences qui correspondent, pour certaines, à différents usages des raisonnements établis dans les brochures d'Eduscol :

- Le raisonnement par l'absurde, comme défini précédemment dans Eduscol (2019b, p. 28), est pratiquement identique à la règle de la preuve indirecte qui se trouve dans Magnus et al. (2025, p. 137). Cependant, les exemples donnés semblent davantage se ramener à l'introduction de la négation (p. 136) : en effet, « La fonction « racine carrée » n'est pas dérivable en 0. » signifie que « non ($\sqrt{}$ dérivable en 0) », et pour le démontrer, on suppose « $\sqrt{}$ dérivable en 0 », ce qui n'est pas syntaxiquement identique à « non (non ($\sqrt{}$ dérivable en 0)) ».
- La disjonction de cas, telle que présentée dans Eduscol (2019a, p. 22 ; 2019b), correspond à la loi du tiers exclu (Magnus et al., 2025, p. 164–165), puisque les cas considérés doivent y être disjoints. Or, certains ouvrages font fi de cette condition de cas disjoints ; il s'agit alors d'une élimination de la disjonction, définie dans Magnus et al. (2025, p. 133), étant même référencée comme « proof by cases » [« disjonction de cas »] à la page 178.
- La « déduction », ou modus ponens, telle que définie dans Eduscol (2016, p. 2), rejoint précisément l'élimination de la conditionnelle, définie dans Magnus et al. (2025, p. 121), et dont il est également mentionné qu'elle « is also sometimes called modus ponens » [« est aussi parfois appelée modus ponens »], pour davantage justifier leur équivalence.
- La double implication, définie dans Eduscol (2019a, p. 16), cherche à démontrer une équivalence entre deux assertions, en montrant d'abord un sens, puis un autre. Il s'agit, selon Magnus et al. (2025, p. 130–131), de l'introduction de la biconditionnelle. Elle est à distinguer du raisonnement par équivalence, aussi définie dans Eduscol (2019a, p. 16), et usant principalement de la transitivité de la biconditionnelle, à savoir l'exercice C. 6. des exercices pratiques de Magnus et al. (2025, p. 139–141).

Récapitulons un peu ce qu'on a fait jusqu'ici. On a réussi à identifier diverses inférences utilisées dans le secondaire, et nous avons établi un lien entre ceux-ci et les inférences formelles de la logique classique, plus spécifiquement de la déduction naturelle, afin de nous donner un cadre plus rigoureux pour étudier et, espérons-le, identifier/classifier les inférences employées par les élèves.

Le problème, désormais, c'est que les inférences élèves, et même certains raisonnements mobilisés et parfois encouragés – dans une certaine mesure, tout du moins en mathématiques au secondaire (je veux bien sûr parler des raisonnements inductifs), ne suivent pas toujours le cadre de la logique classique.

1.2.3 Contra-classicismes

Deloustal-Jorrand (2001, p. 38) émet « l'hypothèse que [...] les élèves [utilisent] la propriété-en-acte suivante : « $\mathcal{A} \Rightarrow \mathcal{B}$ n'a pas d'intérêt lorsque $\mathcal{A}$ est fausse ». De là, peut aussi découler la propriété-en-acte : « $\mathcal{A} \Rightarrow \mathcal{B}$ est fausse lorsque $\mathcal{A}$ est fausse ». » Cette règle, qu'elle abrège en P3b (p. 57), fait écho à une règle médiévale appelée « *ex falso nihil sequitur* » [« rien ne suit d'une contradiction »], notamment présente chez les disciples de Robert de Melun (1095–1167) (Lenzen, 2022). La notation de Fitch est suffisamment robuste pour ériger la formulation qu'en fait Deloustal-Jorrand en tant qu'inférence formelle :

$$m \quad \left| \begin{array}{l} \neg \mathcal{A} \\ \neg(\mathcal{A} \rightarrow \mathcal{B}) \end{array} \right. \text{ P3b } m$$

Pourtant, si on joint cette règle à la logique classique, on obtient que de toute formule $\mathcal{A}$, on peut démontrer $\vdash \mathcal{A}$, donc en particulier toute contradiction :

$$\begin{array}{l|l} 1 & \neg \mathcal{A} \\ 2 & \neg(\mathcal{A} \rightarrow \perp) \quad \text{P3b} \quad 1 \\ 3 & \mathcal{A} \\ 4 & \perp \quad \neg\text{E} \quad 1, 3 \\ 5 & \mathcal{A} \rightarrow \perp \quad \rightarrow\text{I} \quad 3-4 \\ 6 & \perp \quad \neg\text{E} \quad 2, 5 \\ 7 & \mathcal{A} \quad \text{IP} \quad 1-6 \end{array}$$

Une règle, telle que P3b, qui lorsque conjointe à la logique classique engendre un système incohérent, est dite *contra-classique* (Wansing, 2023), comme les logiques connexives et certaines autres logiques traditionnelles, par exemple. La notation de Fitch est alors

suffisamment flexible pour identifier des inférences élèves qui ne sont pas valides classiquement.

À vrai dire, nous pouvons également identifier des raisonnements non-déductifs. Par exemple, les séquents de la forme $\mathcal{P}(1), \dots, \mathcal{P}(n) \vdash \forall n \in \mathbf{N}^* \mathcal{P}(n)$, lorsque mobilisés, nous permettent d'identifier des raisonnements inductifs.

1.2.4 Adaptation au langage naturel

Afin de rendre plus compatible l'apport certain que la notation de Fitch a sur la formulation d'inférences de façon précise, nous pouvons tenter d'identifier certaines caractéristiques de la notation de Fitch que nous pourrions utiliser dans un contexte de langage naturel. Nous identifions notamment que la notation de Fitch est une écriture des prémisses et conclusion en tant qu'étapes dans l'inférence.

Nous recommandons toutefois d'éviter d'utiliser des sous-preuves explicitement indentées, la portée de la supposition pouvant être assez ambiguë. Pour étayer cela, la façon dont les raisonnements par l'absurde sont définis selon Eduscol peut être résumée ainsi, sans indentation :

1. (Supposons) A est vraie.
2. (Donc) B est vraie.
3. (Or) B est fausse.
4. (Par l'absurde) A est fausse.

Selon l'application que l'on en fait, il est difficile d'interpréter jusqu'où la supposition s'applique : si ce n'est que jusqu'à l'étape 2, il s'agit d'un *modus tollens* ; si ce n'est que jusqu'à l'étape 3, il s'agit d'une preuve de la négation ; si cela dure tout du long, il s'agit d'un schéma inférentiel qui dit que des séquents $A \vdash B$ et $A \vdash \neg B$, on obtient $A \vdash \neg A$ (prouvable classiquement via, par exemple, le principe d'explosion), ce qu'on appellera une auto-contradiction. Un sondage que j'ai réalisé (voir [Annexe F](#)) nous permet d'argumenter davantage en faveur de notre non-utilisation de sous-preuves explicitement indentées. Les répondant avaient notamment cette question :

1. Supposons que $1/3$ est décimal.
2. Alors, il existe n un entier naturel tel que 10 à la puissance n est divisible par 3 .
3. Or, il n'existe aucun entier naturel n tel que 10 à la puissance n soit divisible par 3 .
4. Par l'absurde, $1/3$ n'est pas décimal.

Sur neuf réponses, cinq répondants y ont vu un *modus tollens*, trois y ont vu une preuve de la négation, et un y a vu une auto-contradiction. À noter que la question 1 du questionnaire étant plus fréquemment analysée comme un *modus tollens* ($n = 9$, CI 95% $\subset [0.66, 1.00]$). Empiriquement, la question 3 avait une majorité pour l'auto-contradiction, mais celle-ci n'est pas significative ($n = 7$, CI 95% $\subset [0.39, 0.98]$). Pourtant, tous les raisonnements fondant chaque question du questionnaire se basent entièrement sur la définition posée par le Ministère de l'Éducation, de l'Enseignement Supérieur et de la Recherche via la plateforme Éducol, donc dans le cas de l'étude des raisonnements, et plus généralement des inférences logiques, employés par les élèves, nous faisons le choix de ne pas indiquer de sous-preuve dans les inférences que nous établirons lors de l'analyse *a priori*, à cause de l'ambiguïté de la portée de la supposition, voire dans l'identification de ce qui a statut de supposition ou non, dans la rédaction de preuves, au moins dans le cadre de cette recherche préliminaire.

En outre, les façons d'appliquer une règle d'inférence écrite dans une telle sorte de notation de Fitch généralisée, à un contexte de langage naturel, seront inhéremment plurielles, que ce soit par la polysémie des mots langagiers, ou les différences d'interprétation qui dépassent le seul cadre syntaxique. Nous sommes donc parfaitement au fait que l'identification de ces étapes dans des productions d'élèves sera difficilement objectivable. Il nous faudrait alors un outil qui permet de comparer deux phrases en langage naturel, pouvant par exemple déterminer par exemple un pourcentage de similarité sémantique entre deux phrases qui, *a contrario* d'une analyse en termes d'axes syntagmatique et pragmatique, se verra plus quantitative que qualitative, et qui pourrait au moins tenter d'intégrer une part de contexte pertinent. Il s'agit en outre d'un problème analogue à celui de la notation, puisque l'on cherche à poser une valeur numérique à des productions langagières dont le sens dépend souvent du contexte, à l'image de ce que fait un enseignant lorsqu'il attribue une note aux copies qui lui ont été rendues. Cela nous ramène alors aux grands modèles de langage, et à la docimologie.

1.3 Conclusion et problématisation

La recherche montre l'existence de divers biais chez les correcteurs humains, qui impactent la note des élèves, en-dehors de la qualité réelle de leur production. Si les LLM (grands modèles de langage) sont au moins théoriquement capables, par *design*, d'endiguer certains de ces biais, nous ne sommes pas encore capables d'affirmer leur impact sur certains biais, ainsi que sur les écarts de notation entre modèles, même à température nulle (à comportement quasi-déterministe). Les résultats autour des écarts de notation, en particulier, ont pu être décelés via des exercices de multi-correction, avec pourtant des barèmes précis. Afin de rendre le barème aussi précis que possible, nous nous sommes concentrés sur l'identification d'inférences logiques, en adaptant la notation de Fitch pour établir des barèmes précis mais exploitables sur des copies d'élèves.

Nous avons alors la problématique suivante : « **Dans quelles mesures les grands modèles de langage permettent-ils de réduire les biais et écarts d'identification de procédures inférentielles lors de l'analyse *a posteriori* de productions d'élèves, et quel est l'impact du paramètre température sur ces écarts ?** » De la sorte, ce mémoire apporte des éléments de réponse à deux questions simultanément, l'une étant comment intégrer l'intelligence artificielle dans le métier d'enseignant (de mathématiques, tout du moins), et l'autre étant comment réduire les biais d'identification et donc dans les corrections quantifiées de productions d'élèves.

Pour cela, nous testerons statistiquement les observables suivants, dans une modalité de type *multi-correction*, afin de se rapprocher d'expériences relatées dans Merle (2018) que nous expliciterons, à température nulle : l'effet de tendance centrale, en testant si la moyenne est égale à 50 % ; et l'écart-moyen et/ou l'écart-type, en testant s'il diffère ou non de l'écart de notations auquel on pourrait s'attendre de la part de correcteurs humains.

Nous verrons comment tout cela se réalise dans notre deuxième partie, qui concerne explicitement la méthodologie de cette étude.

2 MÉTHODOLOGIE

2.1 Modalités de l'expérience

2.1.1 Exercice central

Notre expérimentation se portera sur le retour de production d'élèves, sur un devoir surveillé qui les poussera à employer diverses inférences, soient-elles médiates (raisonnements) ou non, déductives ou non, etc. Mon tuteur de stage m'ayant informé qu'au cours de mes deux semaines de stage massée du 7 au 18 avril 2025, les élèves de seconde auront un devoir surveillé centré autour des variations de fonctions, j'ai proposé d'écrire le devoir en question moi-même, et ainsi d'y incorporer un exercice qui me permettrait d'apporter des éléments de réponse à la problématique avancée, à savoir dans quelles mesures les grands modèles de langage pourraient réduire les biais et écarts d'identification de procédures inférentielles lors de l'analyse *a posteriori* de productions d'élèves, et l'impact du paramètre température sur ces écarts.

Fabert et Grenier (2019, p. 39–43) propose et analyse deux problèmes qui peuvent nous intéresser autour des variations, à savoir leurs problèmes 3 et 5 :

Problème 3. Indiquer si les propositions suivantes sont vraies (V) ou fausses (F) et justifier.

Propositions	V/F	Justifications
Si $x^2 > 1$ alors $x > 1$		
Si $x < -1$ alors $x^2 > 1$		
$x^2 > 1$ si $x < -1$		
$x > 1$ si et seulement si $x^2 > 1$		

Problème 5. On donne le tableau de variation d'une fonction f définie sur $[0,2]$. Indiquer si les propositions suivantes sont vraies (V) ou fausses (F) et justifier.

x	0	1	2
$f(x)$	-2	1	-5

Il existe un nombre réel de l'intervalle $[0,2]$ dont l'image par f est négative.
Tous les nombres réels de l'intervalle $[0,2]$ ont une image par f négative.
Tous les nombres réels de l'intervalle $[0,2]$ ont une image par f inférieure à 3.

Figure 3. Problèmes 3 et 5 de Fabert et Grenier (2019).

Nous voudrions alors de combiner ces deux problèmes, en prenant le contexte de variations de fonction du problème 5, avec la concentration sur le traitement des conditionnelles dans le problème 3 :

Exercice n°1 On donne le tableau de variation d'une fonction f définie sur $[0; 2]$.

x	0	1	2
$f(x)$	-2	1	-5

2. Indiquer si les propositions suivantes sont vraies, fausses, ou impossible à répondre ; justifier au cas par cas.

- (a) Si $f(x) < -2$ alors $x > 1$?
- (b) Si $x \leq 2$ alors $f(x) \leq 2$?
- (c) Si $f(x) < 1$ alors $x < 1$?
- (d) Si $f(x) > 1$ alors $x > 1$?

Figure 4. Exercice du devoir surveillé pour la classe de 2^{nde}.

À noter que les élèves de cette même classe auront eu, deux jours avant, un sujet bis sur lequel se trouvent des questions similaires, dont celle-ci :

Exercice n°1 On donne le tableau de variation d'une fonction f définie sur $[-1; 4]$.

x	-1	2	4
$f(x)$	4	2	3

2. Indiquer si les propositions suivantes sont vraies, fausses, ou impossible à répondre ; justifier au cas par cas.

- (a) Si $f(x) > 3$, alors $x < 2$?
- (b) Il existe $x \in [-1; 2]$, on a $f(x) > 3$?
- (c) Si $f(x) > 2$ alors $x > 2$?
- (d) Pour tout $x \in [-1; 4]$, on a $f(x) \geq 0$?

Figure 5. Exercice analogue d'entraînement pour la même classe de 2^{nde}.

Nous n'allons toutefois pas analyser cet exercice analogue, puisque nous ne pourrions de toute manière pas vérifier les productions d'élèves, ayant fait cette version *bis* très rapidement sur demande de mon tuteur de stage afin de les entraîner, ne me laissant donc pas le temps d'en faire une analyse *a priori*, me concentrant davantage sur le barème de leur devoir surveillé. Le sujet entier figure dans l'[Annexe E](#).

2.1.2 Analyse *a priori* des inférences dans l'exercice donné

Les inférences ci-dessous seront analysées, dans notre expérience, comme des notes indépendantes, chaque étape étant un item de leur barème associé. Nous n'évaluerons pas les conclusions, ce genre de phrases conditionnelles à quantification implicite pouvant mener à des conclusions très différentes en utilisant pourtant les mêmes arguments (Durand-Guerrier, 1999 ; Cerclé, 2019) ; nous verrons d'ailleurs un exemple avec les inférences 4.2 et 4.3.

2.1.2.1 Question (a)

Inférence 1.1 :

1. $f \geq -2$ sur $[0;1]$

☐ La proposition est vraie

On conclut par contraposée ou par l'absurde/syllogisme disjonctif.

Inférence 1.2 :

1. $f \geq -2$ sur $[0;1]$

2. f est décroissante sur $[1;2]$

3. $f(1) = 1$

4. $f(2) = -5$

5. $-5 < -2$

☐ La proposition est vraie

On a ici à faire à une disjonction de cas, mais où l'élève montre que $f(x) < -2$ n'est pas invérifiable sur $x > 1$. Bien que le raisonnement tel qu'établi ici est classiquement valide, il est à noter que cela peut révéler une contra-classicité de type *ex falso nihil sequitur*, à savoir que nous avons une fonction g telle que $g(x) < -2$ est impossible, disons $g(x) = x^2$ sur $x \in \mathbf{R}$, rien ne pourrait être impliqué à partir de cela dans un tel système contra-classique.

Inférence 1.3 :

1. $f(2) = -5$

2. $-5 < -2$

☐ La proposition est vraie

L'élève utilise ici un raisonnement contra-classique plus explicitement : en effet, il détermine que la proposition est vraie car il y en a un exemple concordant. En d'autres termes, il utilise le séquent $\exists x.\phi \vdash \forall x.\phi$ qui est pourtant contra-classique.

Inférence 1.4 :

1. $-2 < 1$

☐ La proposition est fausse

L'élève a ici une compréhension erronée des fonctions ; il confère à l'image de la fonction les mêmes propriétés que son point d'évaluation – ce qui, par identité des indiscernables de Leibniz, signifie la fonction est au mieux une inclusion, au pire l'identité.

Inférence 1.5 :

1. $f(1) = 1$
2. $1 > -2$

☐ La proposition est fausse

L'élève a ici compris $>$ comme $\geq$ pour dire que $f(1) > -2$ serait un contre-exemple, ou raisonne possiblement par continuité ; toutefois, l'élève comprend aussi l'implication à l'envers, en le traitant comme sa réciproque, ou comme une équivalence.

2.1.2.2 Question (b)**Inférence 2.1 :**

1. 1 est le maximum de f
2. $1 \leq 2$

☐ La proposition est vraie

Inférence 2.2 :

1. $x \leq 2$ est toujours vraie

☐ La proposition est fausse

L'élève fait ici appel à la pertinence (non-classique) de l'implication et une forme de négation par échec (contra-classique).

Inférence 2.3 :

1. $f(x) \leq 2$ est toujours vraie

☐ La proposition est fausse

L'élève fait ici appel à la pertinence (non-classique) de l'implication et une forme de négation par échec (contra-classique).

Inférence 2.4 :

1. $2 \leq 2$

☐ La proposition est vraie

L'élève utilise à la fois l'idée que les fonctions préservent toutes les propriétés des objets sur lesquels ils sont évalués, et l'idempotence de l'implication.

2.1.2.3 Question (c)**Inférence 3.1 :**

1. $f(2) = -5$

2. $-5 < 1$

3. $2 \geq 1$

☐ La proposition est fausse

L'élève saurait comment prouver la négation de l'implication.

Inférence 3.2 :

1. Le maximum de f est 1

☐ La proposition est vraie

L'élève confond la proposition avec sa réciproque, et/ou l'implication avec l'équivalence logique.

Inférence 3.3 :

1. Si $f(x) < 1$, alors $-2 \leq x < 1$

☐ La proposition est vraie

Il s'agit d'une confusion notationnelle entre antécédent et image.

2.1.2.4 Question (d)

Inférence 4.1 :

1. Le maximum de f est 1

2. Si l'antécédent est faux, l'implication est vraie

☐ La proposition est vraie

À moins que l'élève connaisse parfaitement l'implication classique, il y a peu de chance de voir apparaître cette solution puisqu'il s'agit d'une connaissance hors-programme.

Inférence 4.2 :

1. Le maximum de f est 1

☐ La proposition est fausse

L'élève utilise ici la règle contra-classique d'*ex falso nihil sequitur*, telle qu'identifiée dans Deloustal-Jorrand (2001) en tant que propriété P3b.

Inférence 4.3 :

1. Le maximum de f est 1

☐ Impossible de conclure

L'élève utilise ici la règle contra-classique d'*ex falso nihil sequitur*.

Inférence 4.4 :

1. Si $f(x) > 1$, on a $-5 \leq x < 1$

☐ La proposition est fausse

L'élève confond image et antécédent.

2.1.3 Recueil de données et modèles

Nous mettrons les étapes identifiées des inférences dans une 2-liste en Python, dont le premier indice indique l'exercice, – de 0 à 3 pour désigner les exercices (a) à (d), – le deuxième indiquant quant à lui l'étape d'inférence. Les réponses des élèves seront quant à eux dans une 3-liste dont le premier indexant les élèves, le deuxième l'exercice (de 0 à 3), et le troisième les propositions dans la réponse de l'élève concerné à l'exercice concerné. Nous essaierons au mieux de retranscrire chaque proposition des élèves *verbatim* depuis les productions qu'ils auront faites, mais nous devons casser chaque réponse en plusieurs propositions quoi qu'il arrive. Nous ne comparerons toutefois que les prémisses, à cause des raisons citées au tout début de la section [2.1.2](#).

On générera ensuite un tableur CSV pour les réponses du LLM, dont les indices désignent successivement :

1. Les numéros d'élève (0 à 31) ;
2. Les numéros d'exercice (0 à 3) ;
3. Les propositions de réponses d'élèves ;
4. Les étapes d'inférence associées ;
5. Les réponses des LLM.

Nous pouvons utiliser une *flowchart* pour mieux représenter ce processus, afin de mieux le digérer et le visualiser :




Figure 6. Une *flowchart* qui décrit le processus à la production des données centrales à ce mémoire. Voir Annexe G pour un exemple de traitement de copie d'élève.

Pour calculer la note associée à l'élève pour chaque inférence *a priori*, on la découpe étape-par-étape, en prenant le pourcentage de concordance maximal entre l'étape *a priori* parcourue et les différentes propositions élèves liés au même numéro exercice, puis en prenant la moyenne des concordances pour chaque étape de sorte à donner la note finale d'utilisation de ladite inférence par l'élève (en %). L'étape de requête (vers le coin bas-droite du diagramme) est l'étape susceptible d'engendrer des hallucinations.

Pour établir les réponses des LLM, nous utiliserons alors divers modèles disponibles sur Ollama, plutôt que les modèles d'OpenAI, et ce, pour plusieurs raisons :

- Les modèles d'OpenAI, de la famille GPT, sont des modèles propriétaires et lucratifs. Étant donné le nombre de comparaisons que nous devons faire, cela reviendrait très cher, et je n'ai pas les moyens de faire autant d'appels à l'API d'OpenAI.
- Une autre raison est le coût écologique : pouvoir tourner ces modèles en local, hors-ligne, permet d'éviter d'envoyer de nombreuses requêtes à des serveurs centralisés sur le web, et donc de limiter les surcharges réseaux, et l'empreinte

carbone, engendrés par l'accumulation de tâches aussi coûteuses. (Khan et al., 2025, p. 3)

- Enfin, la dernière raison est purement scientifique : les API et autres accès en ligne sont limités dans le temps, et les modèles qui s'y trouvent peuvent être perdus à tout jamais, – ce qu'on appelle parfois du *lost media*, – ce qui viendrait alors empêcher la reproductibilité des expériences fournies dans ce mémoire.

Il faut toutefois noter que OpenAI a sorti, courant août 2025, des modèles sur Ollama, appelés GPT-OSS, toutefois ceux-ci sont trop larges (20 ou 120 milliards de paramètres) pour notre capacité matérielle locale.

Nous devons établir le paramétrage des modèles. Pour cela, le *package* Python `ollama` admet une méthode `ollama.chat`, dans laquelle nous pouvons identifier divers paramètres pour notre test de performance (ce qu'on appelle plus communément un *benchmark*) :

- Tout d'abord, le paramètre `model`, duquel nous choisirons le modèle.
- Ensuite, le paramètre `messages`, auquel nous assignerons `[{'role' : 'user', 'content' : prompt}]`. Les *prompts* seront initialisés selon le schéma suivant :

CONTEXTE : Un exercice de mathématiques en classe de seconde (lycée) sur les variations d'une fonction définie sur $[0;2]$.

OBJECTIF : On attend que l'élève dise, possiblement en ses mots, que "*étape d'inférence*".

RÉSULTAT : L'élève a dit "*réponse de l'élève*" à la place.

ATTENTES : Ne réponds qu'un pourcentage, pas de phrase ou de mot.

CONCORDANCE (en %) =

Un paramètre `stream` que nous poserons comme **True**. *Post-scriptum : nous avons testé si les LLM comprennent bien ce prompt et donnent des résultats cohérents, et*

ceux-ci donnent exactement ce qui est attendu dans la moitié des cas, comme il sera établi dans le 2.2.3.

- Un paramètre `options`, dans lequel nous pouvons établir, entre accolades ;
 - Le paramètre `temperature`, que nous changerons d'une façon que nous détaillerons par la suite.
 - Le paramètre `num_predict`, que l'on gardera fixe de sorte à n'avoir qu'au plus 50 tokens.
- À cause des modèles plus récents, il faut également désactiver l'option de narration de pensée en mettant le paramètre `think` sur `False`, afin de rendre ce qu'il génère plus concis pour y exploiter une valeur numérique – ne vous inquiétez pas, cela n'empêchera pas de voir des hallucinations explicites durant notre expérimentation.

Cela nous donnera alors un code qui peut être résumer en une ligne, à savoir `ollama.chat (model = llm, messages = [{'role' : 'user', 'content' : prompt}], stream = True, options = {'temperature' : température, 'num_predict' : 50}, think = False)`. Nous traiterons la réponse du LLM pour former un nombre décimal français à partir du texte généré.

2.2 Tests statistiques

2.2.1 Effet de tendance centrale, température fixée

Le biais de tendance central est défini dans la section 1.1.1, et se caractérise par une agrégation des notes autour de la moyenne – qu'on peut lier, sinon considérer comme conséquence, à la loi de Posthumus. Pour tester cette hypothèse, on pose n le nombre d'inférences dans l'analyse *a priori*, à savoir 16 ici ; μ la moyenne théorique des prévalences d'inférences, et $\bar{x}$ pour sa version empirique. Il suffit alors d'effectuer des tests z bilatéraux, où l'on comparera les hypothèses suivantes :

$$H_{0\sigma} : \mu = 0.5$$

$$H_{1\sigma} : \mu \neq 0.5$$

Nous avons alors la statistique $z = \frac{\bar{x}-0.5}{\sqrt{\frac{0.5(1-0.5)}{16}}} = 8\bar{x} - 4$, de laquelle nous pourrions alors déterminer la valeur p associée. Si cette valeur p est inférieure à 0.05, nous considérerons qu'il y a significativement trop peu de biais de tendance centrale, si tant est qu'il y en ait un. La commande `2*scipy.stats.norm.cdf(-abs(z))` permet de déterminer cette valeur p sur Python. La normalité de cette statistique est justifiée par la loi de Posthumus.

2.2.2 Écarts de notation, température fixée

Dans nos *desiderata* posés dans la section 1.1.1, nous voulions établir que les écarts entre modèles sont moindre que les écarts entre correcteurs humains. Il est difficile de trouver des études analogues, que ce soit en termes de récence de l'étude, de niveau de classe, de matière scolaire, ou même tout simplement de problème similaire.

Merle (2018) relate une des premières études sur le sujet est celle de l'enquête Carnegie (Laugier & Weinberg, 1936), dans laquelle nous trouvons notamment que six professeurs de mathématiques, dont celle des mathématiques, ont corrigé les mêmes 100 copies du bac, conduisant à une moyenne des écarts de 2.1 points sur 20. De même, une expérience analogue s'y trouvait, les auteurs trouvant un écart moyen de 1.9 points sur 20 répartis sur six autres professeurs et 100 autres copies. En supposant une loi normale, l'écart-type σ et l'écart moyen **EM** sont liés par la formule $\sigma = \sqrt{\frac{\pi}{2}}EM$, les deux moyennant à un écart-type d'environ 2.5 points sur 20. En termes d'études plus récentes, Merle (2018) relate également des expériences semblables sur des corrections de copies de sciences économiques et sociales, une même copie notée par trente correcteurs a admis un écart-type de 2.4 points sur 20. On prendra pour hypothèse de travail que l'écart-type de *multi-correction* d'une même production par différents professeurs en mathématiques est de 0.12, ce qui équivaut à 2.4/20 ou 12 %.

Ainsi, nous pouvons effectuer un test bilatéral sur un écart-type par inférence de l'analyse *a priori*, en posant la statistique $\chi = \frac{\sqrt{n-1} \cdot s}{0.12}$, où s est l'écart-type observé pour l'item ciblé dans l'échantillon, et n le nombre de modèles regroupés, qui nous permettra d'établir un intervalle de confiance à 95 % pour l'écart-type autour de 0.12. Dans le cas où χ serait

en-dehors dudit intervalle, celui sera alors soit minorant, soit majorant, auquel cas, nous pourrions expliciter les valeurs p associées à ces tests statistiques unilatéraux respectifs :

$$H_{0b} : s = 0.12 ; H_{1b\ min} : s < 0.12$$

$$H_{0b} : s = 0.12 ; H_{1b\ maj} : s > 0.12$$

Nous considérerons alors que nous avons effectivement moins d'écart si la valeur p associée peut être calculée grâce à la fonction `scipy.stats.chi.cdf` sur Python.

2.2.3 Choix et catégorisation des modèles, température et *hardware* utilisé

Pour parler de validité de statistique, nous testerons autant de modèles possibles, chacun à température nulle pour minimiser autant que possible la part d'aléa. Théoriquement, cela devrait même enlever tout aléa, mais en pratique, le matériel informatique utilisé peut rendre les générations non-déterministes, même à température nulle (Weinmeister, 2024). Afin d'être complètement transparent, voici alors mon matériel :

- Type du système : Système d'exploitation 64 bits, processeur x64
- Processeur : 11th Gen Intel® Core™ i5-1135G7 @ 2.40 GHz 2.42 GHz
- Mémoire (RAM) : 8.00 Go (7.83 Go utilisable)

En termes de modèles utilisés, nous avons parcouru [la librairie Ollama](#) pour dégager un maximum de modèles possibles. Nous avons principalement établi les critères suivants :

- A. Le modèle doit être équipé d'une version disponible ayant entre sept-milliard (compris) et neuf-milliard (compris) de paramètres, afin de mitiger l'impact du nombre de paramètres dans notre étude.
- B. Le modèle ne doit pas être affiné dans une tâche spécifique extérieure à notre usage, notamment en ce qui concerne les modèles orientés programmation (e.g. qwen2.5-coder, Code Llama) ou visuel (e.g. LLaVA, qwen2.5vl).
- C. Le modèle doit être pris dans sa forme la plus actuelle possible au moment de son choix (e.g. préférer Llama 3.1 à Llama 3 ou 2), et en sa forme la moins dérivée

possible (e.g. préférer Mistral à YARN-Mistral, ce dernier étant une extension du premier).

- D. Durant l'expérimentation, si le modèle semble rapporter des `nan` systématiquement dès les premières générations, nous nous octroyons le droit de les laisser tomber, car inexploitable.

Avant de commencer l'expérimentation, nous avons testé chaque modèle choisi sur les quatre premières comparaisons afin de pouvoir laisser tomber ceux qui renvoient systématiquement `nan` en réponse, ainsi que pour pouvoir établir une catégorisation pertinente de la cohérence des modèles, dans le but d'affiner les résultats si besoin – dans ce dernier cas, nous avons établi qu'un modèle est *plus sain* si les trois premières comparaisons sont notées 0 %, et la quatrième 100 %. Le fait d'avoir établi ce filtre au préalable, plutôt qu'au cours de l'expérimentation, permet d'éviter de faire du dragage de données (ou *p-hacking*). De plus, un tel filtre, même si établi au préalable, pourrait tout de même nous confronter au paradoxe de Simpson : la conclusion que nous obtiendrons, en considérant tous les modèles, pourrait contredire celles relatives à chaque catégorie de modèles (*saines* contre non-*saines*).

Notre liste finale est constituée de llama3.1:8b, mistral:7b, gemma:7b, qwen3:8b, deepseek-r1:8b, olmo2:7b, wizardlm2:7b, dolphin3:8b, hermes3:8b, granite3.3:8b,¹ openchat:7b, aya:8b, cogito:8b, glm4:9b, exaone3.5:7.8b, starling-lm:7b, falcon3:7b, marco-ol:7b, tulu3:8b, notus:7b, neural-chat:7b, xwinlm:7b, vicuna:7b, stable-beluga:7b, et command-r7b:7b (25 modèles). Cela nous donne alors un intervalle de confiance de [3.53, 6.27] pour la statistique du test sur les écarts de notation.

Les modèles *plus sains*, selon cette première expérimentation, sont mistral:7b, gemma:7b, olmo2:7b, dolphin3:8b, granite3.3:8b, openchat:7b, cogito:8b, starling-lm:7b, falcon3:7b, tulu3:8b, neural-chat:7b, et stable-beluga:7b (12 modèles au total).

¹ Depuis l'expérimentation, le modèle granite4:tiny-h (7b) est sorti le 2 octobre 2025. L'expérimentation était à jour jusqu'alors.

Post-scriptum : les modèles llama3.1:8b, qwen3:8b, hermes3:8b, et glm4:9b donnent au moins des notes inférieures (ou égales) à 50% pour les trois premières comparaisons, et des notes plus proches de 100% pour la troisième comparaison.

3 EXPÉRIMENTATION

3.1 Recueil de données et expérimentation

3.1.1 Déroulement et recueil des données élèves dans l'évaluation

L'évaluation s'est déroulée dans un lycée public du troisième arrondissement de Lyon le mercredi 16 avril 2025 de 8h40 à 9h35, dans une classe assez hétérogène et globalement peu investie. La salle était composée de tables à place unique, que le tuteur et moi avons disposés, de sorte à maximiser la distance entre les élèves pour atténuer le facteur triche, et nous permettre de passer plus facilement dans les rangs pour surveiller – ce qui a également contribué à réduire la possibilité de triche. Nous n'excluons pas qu'il y en ait tout de même eu, mais nous n'avons pas pu observer de telle action en flagrant délit.

À la fin de l'évaluation, comme nous l'avions convenu avec mon tuteur de stage au préalable, j'ai pu emmener les copies d'élèves chez moi afin de les corriger pour le lendemain. J'en ai alors profité pour scanner les réponses d'élèves pour l'exercice qui nous intéresse pour ce mémoire, en prenant soin d'anonymiser les réponses d'élèves de deux façons, en rognant chaque image pour ne comporter rien d'autre que l'exercice-même. J'ai pu ainsi analyser les propositions qu'utilise chaque élève pour chaque exercice, afin de pouvoir les comparer avec les étapes que j'avais anticipées dans mon analyse *a priori*. Je précise qu'ils n'ont pas été notés de manière effective sur leur bulletin par le biais d'une IA.

3.1.2 Note moyenne, ou prévalences, de chaque inférence




Figure 7. Graphique présentant la note moyenne en pourcentage (formes carrées, en ordonnée) pour chaque inférence (en abscisse), avec les bornes de l'intervalle de confiance à 95 % associée à chaque moyenne (formes triangulaires). Les inférences (en abscisse) sont triées dans l'ordre décroissant de la moyenne qui leur est associée.

Par leur moyen de notation comme indiqué sous la figure 6, section 2.1.3, les inférences avec les moyennes les plus hautes seront considérées comme les plus prévalentes.

Les intervalles de confiance associés à chaque inférence chevauchent toutes les moyennes empiriques. Ainsi, nous ne pouvons pas dégager de groupes d'inférences significativement plus prévalentes que d'autres. Ces intervalles de confiance à 95 % sont presque tous bornés supérieurement par 50 %, hormis pour celui de l'inférence 2.3 (faisant appel à une implication pertinente et une négation par échec, contra-classique).

La plupart des inférences, même si elles ne peuvent pas être comparées entre elles de façon significative, semblent globalement rares. En toute logique, ces exercices devraient permettre aux modèles de moins souffrir d'un biais de tendance centrale, et donner des moyennes qui tendent généralement vers le bas dans ce contexte-ci. Toutefois, même si nos efforts de catégorisation dans la section 2.2.3 paraissent montrer qu'au moins les deux tiers comprennent assez bien la tâche à accomplir, ces moyennes restent sujettes à précaution.

3.1.3 Effet de tendance centrale




Figure 8. Graphique présentant la valeur de la statistique z (en ordonnée) associée à chaque modèle (en abscisse), avec deux lignes rouge indiquant les bornes de l'intervalle de confiance à 95 % de la statistique z dans l'hypothèse d'un biais de tendance centrale (H_{0a}). Les modèles (en abscisse) sont triés dans l'ordre décroissant de la statistique z qui leur est associée.

Sur un plan purement analytique, quatorze modèles sur les vingt-cinq testés (fréquence empirique 56 %) permettent de rejeter l'hypothèse d'une tendance centrale – sans pour autant confirmer qu'ils en ont une, cependant. Ces deux modèles sont `marco-01:7b` et `notus:7b`. En entrant `binom.test(14, 25, alternative="greater")$conf.int` dans le langage de programmation R, on obtient que l'intervalle de confiance de Clopper-Pearson à 95 % unilatéral droit de la fréquence des modèles rejetant ladite hypothèse H_{0a} est inclus dans $[0.37, 1]$. Le nombre de faux positifs attendus est d'environ $0,05 \times 25 = 1,25$.

Résultat, nous en interprétons qu'au moins 37 % ne sont pas atteints d'un biais de tendance centrale ($p < 0.05$). Nous avons donc confiance à 95 % qu'au moins trois quarts des grands modèles de langage permettent d'évaluer les élèves sans biais significatif autour de la moyenne, et donc que les grands modèles de langage semblent généralement pouvoir atténuer ce biais-ci, allant dans le sens de nos *desiderata*.

3.1.4 Écarts inter-modèles




Figure 9. Graphique présentant la valeur de la statistique χ (en ordonnée), calculée en prenant en compte tous les modèles, associée à chaque item-inférence (en abscisse), avec deux lignes rouge indiquant les bornes de l'intervalle de confiance à 95 % de la statistique χ pour l'hypothèse d'un écart entre modèles égal à l'écart entre humains (H_{0b}). Les inférences (en abscisse) sont triées dans l'ordre croissant de la statistique χ qui leur est associée.

Seules trois inférences, à savoir les inférences 4.2, 4.3 (*ex falso nihil sequitur*, contra-classiques), et 4.1 (implication matérielle, classique), ne sont pas associées à des écarts-types significativement distincts de l'écart de 12 % observé chez les humains. Dans tous les autres cas, l'écart est significatif, mais significativement plus important que l'écart humain. Cela nous donne une fréquence empirique 75 % d'inférences (sur 16) qui mènent à davantage d'écarts de notation sur l'ensemble des modèles que pour les correcteurs humains, ce qui nous mène à un intervalle de confiance de Clopper-Pearson à 95 % unilatéral droit associé à cette fréquence, inclus dans $[0.51, 1]$. Le nombre de faux positifs attendus est d'environ $0,05 \times 25 = 1,25$.

Nous en interprétons qu'au moins 51 % des inférences, tous modèles confondus, sont évaluées avec des écarts de notation significativement pires, tous grands modèles de langage confondus, que les écarts observés chez les correcteurs humains. Ainsi, les grands modèles de langage, sans outre *assainissement* dans le choix des modèles, semblent, globalement,

non seulement ne pas atténuer les écarts de notation, mais même les exacerber, allant alors à contresens de nos *desiderata*.




Figure 10. Graphiques présentant la valeur de la statistique χ (en ordonnée), calculée en prenant d'abord en compte seulement les modèles jugés *plus sains*, puis seulement les modèles jugés *moins sains*, associée à chaque item-inférence (en abscisse), avec deux lignes rouge indiquant les bornes de l'intervalle de confiance à 95 % de la statistique χ pour l'hypothèse d'un écart de correction entre modèles identique aux humains. Les inférences (en abscisse) sont triées dans l'ordre croissant de la statistique χ qui leur est associée.

Seules deux inférences, la 1.4 et la 1.5, permettent de rejeter H_{1b} , et ce, seulement dans le cas des modèles jugés *moins sains*, où ces deux inférences sont notées avec significativement plus d'écarts qu'entre des correcteurs humains en mathématiques. Le nombre de faux positifs attendus au total est $0,05 \times (12 + 13) = 1,25$.

Nous en tirons que notre tentative d'assainissement des modèles n'est pas suffisamment probante, en cela qu'elle nous mène à une forme faible de paradoxe de Simpson. En effet, la conclusion de chaque cas de cette partition (modèles jugés *plus sains*, contre modèles jugés *moins sains*, selon leurs réponses aux quatre premières comparaisons du *benchmark* utilisé), qui serait que la majorité des inférences ne sont pas notées avec un écart entre modèles significativement différent des correcteurs humains, contredit la conclusion globale selon laquelle la majorité des inférences sont notées avec un écart significativement pire. Nous n'exploiterons donc pas cette donnée-ci, ces non-significativités étant principalement dues à la taille trop petite de chacune des deux constituantes de cette partition ($n = 12$, $n = 13$).

Accorder du poids à la conclusion hâtive que l'on peut retirer du bruit engendré par cette partition, aux dépens de la conclusion générale, serait intellectuellement malhonnête.

3.1.5 Hallucinations

Au cours de l'expérimentation, malgré la compréhension globale du prompt (environ la moitié donnant exactement ce qui était attendu dans les quatre premières comparaisons, cf. 2.2.3), le programme codé pour générer les fichiers .csv centraux à ce mémoire nous a permis de voir quelques *hallucinations* notables, qui mettent à mal la crédibilité des notes données par divers grands modèles de langage. Afin d'éviter d'en faire un florilège succinct, nous nous concentrerons sur celles observées dans deux modèles de langage distincts :

- Pour notus:7b, en comparant l'étape " $1 \leq 2$ " (*a priori*) à la proposition-élève " $x \leq 2 = f(x) \leq 2$ " pour l'élève 15 (# 14 dans le .csv), à l'exercice 2 (# 1 dans le .csv), le modèle décrit, je cite : "100% of responses should contain "1 <= 2". Il comprend donc, dans ce contexte-ci, la concordance comme la fréquence attendue.
- vicuna:7b hallucine des tâches intermédiaires parfois sans aucun rapport avec la tâche élève, créant ainsi plusieurs pourcentages – le programme d'analyse du texte généré n'extrait que le premier pourcentage, ou le premier nombre qu'il y a sinon, ou nan ("*not a number*") si aucun nombre n'est détecté. Concentrons-nous, encore une fois, sur l'élève 15 (#1 dans le .csv) à l'exercice 2 (#1 dans le .csv). En comparant l'étape " 1 est le maximum de f " (*a priori*) à la proposition-élève " $x \leq 2 = f(x) \leq 2$ ", le modèle décrit, je cite :
"* Compréhension orale : 70%
* Expression écrite : 85%"
Le modèle confère donc à l'exercice un aspect oral qui n'est non seulement pas suggéré, mais tout à fait inadéquat à la tâche que les élèves ont réalisée (un devoir surveillé dans le silence total).

En reproduisant les expériences de ce mémoire, vous pourrez constater par vous-mêmes les nombreuses hallucinations que produisent les différents modèles utilisés. Bien que la plupart d'entre eux ne donnaient effectivement qu'un nombre ou pourcentage, le fait de ne pas

Page 46

avoir vérifié leur processus de *réflexion* (au sens des LLM) nous pousse à nous questionner quant à la pertinence et au bien-fondé des notes qu'elles donnent, ne faisant qu'appuyer et confirmer les propos du Ministère de l'Éducation nationale et de la Jeunesse (2025) :

« Conformément au règlement européen sur l'IA, toute décision s'appuyant sur l'IA, ayant un impact significatif sur l'évaluation des apprentissages, les parcours des élèves ou les parcours professionnels, doit faire l'objet :

- d'une supervision humaine garantissant son usage équitable et son explicabilité ;
- d'une validation préalable par l'autorité compétente. »

3.2 Conclusion de l'expérimentation

Une partie des grands modèles de langage tendent à éviter la tendance centrale : empiriquement, la plupart des modèles (14 sur 25) rejettent l'hypothèse d'une tendance centrale, ce qui correspond toutefois à, au moins, 37 % des modèles avec $p < 0.05$. Cependant, les résultats actuels indiquent que les écarts de notation sont exacerbés pour plus de 51 % des inférences ($p < 0.05$) si l'on considère tous les modèles, pourtant tous à température nulle. En outre, les modèles peuvent halluciner des tâches annexes (e.g. `vicuna:7b` et sa note de compréhension orale pour un devoir écrit), mal-comprendre la consigne (e.g. quand `notus:7b` prend la “concordance” entre deux propositions comme la “fréquence attendue” de l'un des deux), j'en passe et des meilleurs.

Nous avons donc des éléments réponses de taille à fournir à notre problématique qui, nous le rappelons, s'agissait de déterminer « dans quelles mesures les grands modèles de langage permettent de réduire les biais et écarts d'identification de procédures inférentielles lors de l'analyse *a posteriori* de productions d'élèves, et quel est l'impact du paramètre température sur ces écarts ». Nous voyons que le résultat est pour l'instant mitigé, puisque bien que certains semblent permettre d'éviter les biais de tendance centrale (au moins 37 % d'entre eux, $p < 0.05$), nous ne pouvons pas affirmer qu'ils permettent d'atténuer les écarts d'identification de procédures inférentielles lors de l'analyse *a posteriori* de productions d'élèves, même malgré une température nulle – en réalité, dans le cas où l'on admet tous les modèles confondus, nous obtenons des écarts supérieurs à ceux des correcteurs humains.

4 CONCLUSION

Notre problématique centrale était de déterminer dans quelles mesures les grands modèles de langage permettent de réduire les biais et écarts d'identification de procédures inférentielles lors de l'analyse *a posteriori* de productions d'élèves, et l'impact du paramètre température sur ces écarts. Le bilan que nous pouvons dresser est pour l'heure mitigé : un potentiel certain, mais des limites techniques et conceptuelles encore importantes, voire sévères.

Avant même de faire ces expérimentations, nous avons établi, dans la conclusion de la section sur les modèles de langage dans la partie théorique, de nombreux *desiderata* pour l'atténuation de biais de notation que les grands modèles de langage permettent de satisfaire :

- a) Un traitement sans mémoire : l'évaluation de la production ne dépend que de son contenu, et non d'informations antérieures. Toutefois, dans le cas de l'utilisation d'un agent conversationnel en ligne, cela demande soit un contexte suffisamment petit, soit en prenant soin d'avoir des conversations différentes, en prenant soin de désactiver la mémoire inter-conversations.
- b) Plusieurs corrections d'une même production, à partir de ce seul traitement, doivent amener à un écart significativement moindre (effet d'écart de notation) : un modèle à température nulle devrait théoriquement donner toujours le même résultat pour un même prompt, – bien que le matériel à disposition pourrait affaiblir cet aspect *déterministe*.
- c) Un traitement pratique pour les enseignants : une explication précise de sa mise en œuvre a pu être donnée, afin d'aider les enseignants à s'approprier l'outil de traitement avec de moindres difficultés.

Qui plus est, les capacités émergentes des grands modèles de langage leur permettent un traitement automatique du langage leur permettant, entre autres, de prendre en compte des aspects aussi bien syntaxiques que sémantiques d'un *prompt* donné. Les prompts donnés ont d'ailleurs permis à la moitié des modèles de donner les mêmes notes que nous avons

données aux quatre premières comparaisons, quatre autres les mettant globalement dans le bon ordre, mais n'osant pas mettre 0% et/ou 100% : en pratique, cette compréhension relativement bonne des *prompts* donnés concerne alors environ les deux tiers des modèles testés. Or, nous ne savions pas, de prime abord, si les LLM suivaient la loi de Posthumus et, alors, si elle était atteinte d'un biais de tendance centrale. Nous ne savions pas non plus si les modèles avec plus ou moins d'écarts entre eux qu'entre des correcteurs humains.

Un premier résultat expérimental, permettant de compléter ces aspects théoriques, concerne la capacité des modèles à contourner certains biais humains bien identifiés. Notre analyse suggère en effet que certains permettent d'éviter une part significative des biais de tendance centrale ($p < 0.05$), ce pour au moins 37 % des grands modèles de langage (IC 95%), et empiriquement pour plus de la moitié des modèles testés. À noter que pour chaque modèle, chaque note a été donnée indépendamment, sans mémoire les unes des autres ; nous n'avons pas cherché à déterminer si le fait d'attribuer ces notes dans la même fenêtre de contexte impacte, ou non, les notes futures.

Ce succès relatif autour du biais de tendance centrale est toutefois à contraster avec les faiblesses observées sur les écarts de notation inter-modèles. En effet, nous ne sommes pas en mesure d'affirmer que les modèles atténuent les écarts d'identification de procédures inférentielles. Au contraire, lorsque l'on regarde les écarts entre tous les modèles testés, les écarts générés deviennent même significativement supérieurs à ceux observés entre correcteurs humains ($p < 0.05$), et ce, pour au moins 51 % des inférences (IC 95 %). L'ajustement du paramètre température à une valeur nulle, censée garantir une variance théoriquement nulle, – quoique potentiellement influencée par le matériel utilisé, – ne suffit pas à résoudre ce problème fondamental de fiabilité.

La viabilité des LLM dans la tâche d'évaluation est par ailleurs compromise par leur propension aux erreurs critiques, qu'il s'agisse d'hallucinations pures, comme la création d'une note de compréhension orale pour un devoir écrit (*vicuna:7b*), ou de mécompréhensions profondes de la consigne, tel le modèle *notus:7b* interprétant la « concordance » comme une « fréquence attendue ». Ces défaillances nous poussent à remettre en cause leur utilisation dans un contexte à forts enjeux comme l'évaluation

scolaire, nous menant à préconiser la supervision humaine en l'état actuel. Nous pouvons être poussés à considérer que de nouveaux biais, liés aux hallucinations des grands modèles de langage, pourraient émerger cette nouvelle technologie – nous devons toutefois indiquer que des recherches futures seront nécessaires pour confirmer l'existence d'au moins un tel biais.

4.1 Qu'en tirer pour l'enseignant ?

À cause des écarts inter-modèles exacerbés par rapport aux correcteurs humains, et des hallucinations internes à chaque modèle, nous nous devons de mettre l'accent sur la dangerosité d'utiliser exclusivement un seul modèle ou une seule famille de modèles pour évaluer les élèves sans supervision humaine supplémentaire. Si les grands modèles de langage ont un réel potentiel pour assister l'évaluation et la rendre potentiellement plus objective sur certains aspects, notamment pour la notation sans mémoire et le biais de tendance central, notre mémoire montre que la route vers une aide fiable et autonome pour l'analyse de productions d'élèves est encore longue. Pour le moment, la supervision humaine reste essentielle, et ce même si nous arrivons à réduire les écarts de notation inter-modèles, il nous faudra vérifier que ces modèles ne s'accordent pas à donner des notes en fonction d'hallucinations sévères, pouvant biaiser les notes d'une façon ou d'une autre.

4.2 Ouvertures pour la recherche

Ces constats, bien que critiques pour certains, n'invalident aucunement cette piste de recherche dans la mitigation des biais de notation. La capacité de contrôler la mémoire, ou son absence, reste un point majeur d'atténuation de divers biais. Plutôt, nous pouvons déterminer plusieurs pistes d'amélioration et d'exploration futures.

Tout d'abord, nous devrions intégrer les modèles de la famille GPT dans de prochaines recherches, d'autant plus que la sortie de GPT-OSS courant août 2025 sur Ollama permet de garder l'aspect local. Compte tenu de leur popularité, en dehors même du cadre académique, leur performance et leur comportement face à cette tâche nous semblent indispensables pour juger de l'applicabilité réelle de cette technologie. Similairement, une réflexion sur la pondération des modèles en fonction de leur popularité ou de leur

robustesse pourrait affiner l'analyse globale, ce que notre mémoire n'a ne serait-ce que tenté d'établir.

Dans la foulée des continuations possibles avec plus de ressources matérielles, il nous semble intéressant de déterminer si le nombre de paramètres permet ou non d'atténuer l'écart inter-modèles et/ou l'appétence aux hallucinations. Pour cela, nous pouvons réitérer et étendre nos résultats actuels à ces fins : nous avons déterminé un écart-type empirique inter-modèles, toutes inférences confondues, de 14 % sur 25 modèles, contre l'écart-type de 12 % entre correcteurs humains ; nous avons également choisi une plage de sept milliards (inclus) à neuf milliards (inclus) de paramètres pour les modèles retenus.

Au-delà de la sélection des modèles, un enjeu crucial réside dans la limitation de leurs défaillances. Avant même d'optimiser la réduction des écarts d'évaluation, il est impératif de trouver des méthodes pour contenir les hallucinations et garantir une compréhension juste des consignes. Sans cette fiabilité de base, leur apport restera théorique. Parallèlement, il serait pertinent d'élargir le spectre de l'analyse en concevant des protocoles pour tester d'autres biais docimologiques connus. Enfin, pour valider la portée de ces outils, des études futures pourraient étendre le domaine d'expérimentation à l'intégralité du programme de mathématiques, et pourquoi pas, aux autres disciplines scolaires et universitaires qui reposent sur l'analyse de raisonnements.

Les considérations éthiques et déontologiques esquissés par le Ministère de l'Éducation nationale et de la Jeunesse (2025) forment un enjeu majeur dans l'applicabilité de cette technologie dans le futur : que ce soit leur impact écologique, les reproductions de biais et de discriminations, l'entraînement sur des textes soumis au droit d'auteur rendant la légalité plus qu'incertaine des textes qu'ils produisent, etc.

Enfin, des technologies alternatives ou supplémentaires pourraient également être examinées, notamment l'emploi de vérificateurs formels, afin de voir s'il est possible de rendre un tel type d'outils pratique pour les enseignants, et si son utilisation pratique permet effectivement de réduire les biais de notation.

BIBLIOGRAPHIE

- Armengaud, F. (2006, novembre 18). *Inférence*. Encyclopædia Universalis. <https://web.archive.org/web/20100608134442/https://www.universalis.fr/encyclopedie/inference/>
- Cerclé, V. (2019). *Faire vivre les énoncés contingents dans la classe de mathématiques : pourquoi et comment ?*. Petit x, 110–111, p. 27–55. https://irem.univ-grenoble-alpes.fr/medias/fichier/petit-x-110-111-art2_1612363004720-pdf
- Deloustal-Jorrand, V. (2001). *L'implication. Quelques aspects dans les manuels et points de vue d'élèves-professeurs* [p. 36, 57]. Petit x, 55, p. 35–70. https://irem.univ-grenoble-alpes.fr/medias/fichier/55x3_1561102993655-pdf
- Durand-Guerrier, V. (1999). *L'élève, le professeur et le labyrinthe*. Petit x, 50, p. 57–79. <https://bibnum.publimath.fr/IPX/IGR99258.pdf>
- Eduscol. (2016, mars 26). *Raisonner* [Mathématiques, cycle 4]. Ministère de l'Éducation nationale et de la Jeunesse. <https://eduscol.education.fr/document/17224/download>
- Eduscol. (2019a, août 15). *Raisonnement et démonstration* [Mathématiques, 2^{nde}, voie générale et technologique]. Ministère de l'Éducation nationale et de la Jeunesse. <https://eduscol.education.fr/document/24580/download>
- Eduscol. (2019c, septembre 13). *Représentation des entiers naturels* [Mathématiques, 1^{re}, voie générale]. Ministère de l'Éducation nationale et de la Jeunesse. <https://eduscol.education.fr/document/30025/download>
- Eduscol. (2019b, novembre 25). *Raisonnement et démonstration* [Mathématiques, 1^{re}, voie générale]. Ministère de l'Éducation nationale et de la Jeunesse. <https://eduscol.education.fr/document/24583/download>
- Fabert, C., & Grenier, D. (2019). *Une étude didactique de quelques éléments de raisonnement mathématique et de logique*. Petit x, 87, p. 31–52. <https://bibnum.publimath.fr/IPX/IGR11017.pdf>

- Gao, A. (2017, septembre 26). *Semantic Entailment and Natural Deduction*. Université de Waterloo. https://cs.uwaterloo.ca/~a23gao/cs245_f17/slides/lecture6and7_to_post.pdf
- Grenier, D., Bacher, R., Barbe, H., Bicaïs, H., Charlot, G., Decauwert, M., & Gezer, T. (2019, novembre 12). *Logique et Situations de Recherche pour la Classe* [p. 11]. Institut de recherche sur l'enseignement des mathématiques de Grenoble. <https://irem.univ-grenoble-alpes.fr/recherche-action/raisonnement-logique-situations-de-recherche-pour-la-classe/logique-et-situations-de-recherche-pour-la-classe-498677.kjsp>
- Hiemstra, D. (2009). Language Models. In L. Liu & M. T. Özsu (éds.), *Encyclopedia of Database Systems*. Springer US, p. 1591–1594. https://doi.org/10.1007/978-0-387-39940-9_923
- Khan, T., Motie, S., Kocak, S. A., & Raza, S. (2025). *Optimizing Large Language Models : Metrics, Energy Efficiency, and Case Study Insights* [p. 3]. arXiv. <https://arxiv.org/abs/2504.06307>
- Lecoix, É. (2019). *Docimologie et biais de la notation chiffrée*. <https://web.archive.org/web/20250929150517/http://elecoix.free.fr/didactique/FF%20IA%20IPR%202018-2020/Docimologie.pdf>
- Lenzen, W. (2022). *Rewriting the History of Connexive Logic*. Journal of Philosophical Logic, 51(3), p. 525–553. <https://doi.org/10.1007/s10992-021-09640-6>
- Luo, H., Sun, Q., Xu, C., Zhao, P., Lou, J., Tao, C., Geng, X., Lin, Q., Chen, S., & Zhang, D. (2023, août 18). *WizardMath: Empowering Mathematical Reasoning for Large Language Models via Reinforced Evol-Instruct* [p. 1–5]. arXiv. <https://arxiv.org/abs/2308.09583v1>
- Magnus, P. D., Button, T., Trueman, R., & Zach, R. (2025). Forall x : Calgary. an introduction to formal logic (dbab7fc). Open Logic Project. Récupérée le 4 août 2025, à partir de <https://web.archive.org/web/20250625195228/https://forallx.openlogicproject.org/forallxyyc.pdf>
- Merle, P. (2018). La docimologie ou la science des examens. In *Les pratiques d'évaluation scolaire: Historique, difficultés, perspectives: Les pratiques d'évaluation scolaire: Historique, difficultés, perspectives*. Presses Universitaires de France, p. 87–116.

- Minaee, S., Mikolov, T., Nikzad, N., Chenaghlu, M., Socher, R., Amatriain, X., & Gao, J. (2024, février 20). *Large Language Models: A Survey* [p. 1–2]. arXiv. <https://arxiv.org/abs/2402.06196>
- Ministère de l'Éducation nationale et de la Jeunesse. (2025, juin 13). *Cadre d'usage de l'IA en éducation*. <https://www.education.gouv.fr/cadre-d-usage-de-l-ia-en-education-450647>
- Ministère de l'Éducation nationale et de la Jeunesse. (2020, juillet 9). *Programme de spécialité de mathématiques de terminale générale*. Le Bulletin officiel de l'Éducation nationale. <https://eduscol.education.fr/document/24568/download>
- Ollama. (2024, décembre 6). *Structured outputs* [Ollama blog]. Récupérée le 26 juillet 2025, à partir de <https://web.archive.org/web/20241206172911/https://ollama.com/blog/structured-outputs>
- Peeperkorn, M., Kouwenhoven, T., Brown, D., & Jordanous, A. (2024, mai 1). *Is Temperature the Creativity Parameter of Large Language Models?* [p. 1–8]. arXiv. <https://arxiv.org/abs/2405.00492>
- Rochlin, N. (2024, octobre 8). *LibGuides: Prompt Design For Beginners: Set The Temperature*. <https://web.archive.org/web/20250105153143/https://libguides.uvic.ca/promptdesign/temp>
- Wansing, H. (2023). Connexive Logic. In E. N. Zalta & U. Nodelman (Éd.), *The Stanford Encyclopedia of Philosophy*. Stanford University. <https://plato.stanford.edu/archives/sum2023/entries/logic-connexive/>
- Weinmeister, K. (2024, juillet 17). *Is a zero temperature deterministic?*. <https://web.archive.org/web/20240718021830/https://medium.com/google-cloud/is-a-zero-temperature-deterministic-c4a7faef4d20>
- Wilson D. J. (2019). The harmonic mean p -value for combining dependent tests. In *Proceedings of the National Academy of Sciences of the United States of America*, 116(4), p. 1195–1200. <https://doi.org/10.1073/pnas.1814092116>

GLOSSAIRE

Contra-classicisme

Qui concerne une règle qui, lorsque conjointe à la logique classique, engendre un système incohérent, trivial (où $\vdash \perp$ est un théorème valide), comme les thèses d'Aristote et de Boèce en logique connexive (Wansing, 2023), ou *ex falso nihil sequitur* (Deloustal-Jorrand, 2001 ; Lenzen, 2022).

Docimologie

« Science des examens et des concours, étude de la qualité et de la validité des différents systèmes de notation scolaire et de contrôle des connaissances » (TLFi)

Fenêtre contextuelle (ou contexte)

Paramètre de plafonnage du nombre de *tokens* que le modèle peut prendre en charge.

Grand modèle de langage (large language model, LLM)

De l'anglais *large language model*, un [modèle de langage](#) entraîné sur un très large corpus de texte.

Inférence

Procédure « qui passe de propositions assertives, comme prémisses, à des propositions assertives, comme conclusions. Au sens strict, on distingue l'inférence du raisonnement en ce qu'elle peut être soit médiate soit immédiate [...] tandis que le raisonnement comporte nécessairement des médiations (il est discursif). On distingue aussi l'inférence démonstrative ou déduction [...] et l'inférence non démonstrative [...]. L'inférence déductive est qualifiée de valide ou de non valide ; cette qualification ne se retrouve pas exactement [autrement] [...]. L'inférence valide s'effectue conformément à des règles qui permettent de déduire d'un ensemble de prémisses toutes les conséquences logiques et elles seulement. » (Armengaud, 2006)

Modèle de langage

Outil qui « assigne des probabilités à des bouts de texte [...], basés sur des données d'entraînement. » (Hiemstra, 2009)

Prompt

Afin d'interagir avec un grand modèle de langage, un *prompt* est un texte à partir duquel le modèle génère une réponse appropriée.

Raisonnement

Inférence médiate, explicite.

Température

Paramètre de contrôle de l'hétérogénéité des réponses possibles. Plus la température est basse, plus la distribution sera concentrée autour d'un même texte-réponse.

Token

Élément textuel permettant d'isoler des motifs au sein d'un texte, qu'il soit généré ou saisi dans le *prompt*.

ANNEXES

Annexe A (Modèle de langage markovien)

```
def markovian_language_model (text, prompt=".", n=100) :
    from re import findall
    from numpy import unique, array, zeros, cumsum, searchsorted
    from random import random
    from warnings import filterwarnings
    pattern = r'\w+|(^\\w\\s|'
    states = findall(pattern, text)
    unique_states = list(unique(states))
    state_index = {state: i for i, state in enumerate(unique_states)}
    transitions = zeros((len(unique_states), len(unique_states)))
    for i in range(len(states) - 1) :
        transitions[state_index[states[i]], state_index[states[i+1]]] += 1
    filterwarnings("ignore")
    transitions /= transitions.sum(axis=1, keepdims=True)
    filterwarnings("default")
    output = [prompt]
    for _ in range(n) :
        current_index = state_index[output[-1]]
        if str(transitions[current_index][0]) == "nan" :
            return output
        if not any(transitions[current_index]) :
            break
        rand = random()
        cumm_prob = cumsum(transitions[current_index])
        next_state = unique_states[searchsorted(cumm_prob, rand)]
        output.append(next_state)
    return ' '.join(output)
```

Annexe B (Distribution aléatoire, simulation de température)

```
from random import random
from numpy import sqrt, exp, arange
from matplotlib.pyplot import *
def random_distribution (possible_grades) :
    preeval_rel = []
    for grade in possible_grades :
        preeval_rel.append([grade, random()])
    total = 0
    for couple in preeval_rel :
        total += couple[1]
    eval_rel = []
    for couple in preeval_rel :
        eval_rel.append([couple[0], couple[1]/total])
    return eval_rel
def expected_value (distribution_list) :
    result = 0
    for couple in distribution_list :
        result += couple[0]*couple[1]
    return result
def standard_deviation (distribution_list) :
    result = 0
    expected = expected_value(distribution_list)
    for couple in distribution_list :
        result += (couple[0]-expected)*(couple[0]-expected)*couple[1]
    return sqrt(result)
def heating (distribution_list, log_temperature = 0) :
    total = 0
    for couple in distribution_list :
        total += exp(couple[1]*exp(-log_temperature))
    result = []
    for couple in distribution_list :
        result.append([couple[0],exp(couple[1]*exp(-log_temperature))/total])
    return result
f, ax =.subplots(1)
ax.set_xlim(left=0,right=72)
ax.set_ylim(bottom=0,top=50)
for _ in range(10) :
    possible_grades = [random()*20 for _ in range(_*5+5)]
    distribution = random_distribution(possible_grades)
    deviations = []
    for log_temperature in list(arange(-7-.2*_ ,6,.1)) :
        heated = heating(distribution,log_temperature)
        deviations.append(standard_deviation(heated))
    plot(list(exp(arange(-7-.2*_ ,6,.1))),deviations,"-",color=(1-.1*_ ,0,.1*_ ))
ax.set_xscale('log')
ax.set_xlim(left=.00013,right=403)
ax.set_ylim(bottom=0,top=9)
ax.grid()
xlabel("Température")
ylabel("Écart-type")
show()
```

Annexe C (Page GitHub)

<https://github.com/Usernamealexandraeisnotavailable/memoiremeef/tree/main>

En téléchargeant son contenu en format .zip, – accessible en ouvrant le menu déroulant

<> Code ▾

puis sélectionner “Download ZIP”, – nous pouvons le décompresser dans un répertoire spécifique, puis établir son contenu via le terminal (`tree /f "chemin du répertoire"`), nous donnant alors :


```

| README.md
|
|--- annexes
|    A.py
|    B.py
|
|--- experiences
|    generateur.py
|    ic95_prevalences.py
|    valeurs-p_ecarts.py
|    valeurs-p_moyenne.py
|
|--- analyses
|    analyse_ecarts.ods
|    analyse_ecarts_moins-sains.ods
|    analyse_ecarts_plus-sains.ods
|    analyse_moyenne.ods
|    analyse_prevalences.ods
|
|--- modules
|    analyse.py
|    analysedossier.py
|    decimales.py
|    etapes.py
|    etapescsv.py
|    inferences.py
|    manipcsv.py
|    manipfichiers.py
|
|--- tests
|    aya.csv
|    beluga.csv
|    cogito.csv
|    deepseek.csv
|    dolphin.csv
|    exaone.csv
|    falcon.csv
|    gemma.csv
|    glm.csv
|    granite.csv
|    hermes.csv
|    llama.csv
|    marco.csv
|    mistral.csv
|    neural.csv
|    notus.csv
|    olmo.csv
|    openchat.csv
|    qwen.csv
|    r.csv
|    starling.csv
|    tulu.csv
|    vicuna.csv
|    wizardlm.csv
|    xwinlm.csv
```

Annexe D (Google Drive)

<https://drive.google.com/drive/u/0/folders/10cK9td2bO15ZrsGsosx3-xbfMO60ON-h>

Le dossier .ollama contenant tous les modèles utilisés est disponible sur ce dossier Google Drive. Nous déconseillons toutefois de le télécharger directement dans son entièreté, étant donné son poids considérable (plus de 100 gigaoctets...). En voici l'arbre de ses sous-répertoires :



Annexe E (Sujet complet du devoir surveillé)


2^{ème} [REDACTED] Devoir surveillé n°12 Avril 2025 Durée 1h00
Consignes : Calculatrice autorisée, mais échanges interdits.
Nom, Prénom _____

Exercice n°1 On donne le tableau de variation d'une fonction f définie sur $[0; 2]$.

x	0	1	2
$f(x)$	-2	$\nearrow$ 1 $\searrow$	-5

- Dans un repère orthonormé, dessiner une courbe possible de f .
- Indiquer si les propositions suivantes sont vraies, fausses, ou impossible à répondre ; justifier au cas par cas.
 - Si $f(x) < -2$ alors $x > 1$?
 - Si $x \leq 2$ alors $f(x) \leq 2$?
 - Si $f(x) < 1$ alors $x < 1$?
 - Si $f(x) > 1$ alors $x > 1$?

Exercice n°2 On pose f la fonction définie sur $[-1; 7]$ dont le graphe est le suivant :



- Dresser le tableau de variation de f .
- Comparer $f(4,49)$ et $f(4,51)$, et justifier.

Exercice n°3 Soient les points $A(-4; 4)$, $B(-8; 5)$ et $C(-12; 6)$.

- Calculer $\overrightarrow{AB}$.
- Calculer $\overrightarrow{AC}$.
- Calculer le déterminant de $\overrightarrow{AB}$ et $\overrightarrow{AC}$.
- En déduire que A, B, C sont alignés.
- Soit M le point milieu entre A et C .
 - Calculer les coordonnées de M .
 - En déduire que $M = B$.

Exercice n°4 Un site en ligne proposait des soldes à -30% sur tous ses produits en novembre 2024.

- Un campé valait 335€ avant les soldes. Que vaut-il maintenant ? Arrondir au centime près.
- Une télévision vaut maintenant 1099€. Que valait-elle avant les soldes ?
- Après les soldes, le site remet les prix d'origine de tous ses produits. Déterminer le pourcentage de hausse des prix après les soldes.

Exercice n°5 Quatre amis jouent à un jeu de vingt-deux cartes, dont vingt-et-une de valeurs 1 à 21, et d'une carte *joker* de valeur 0 ou 22 selon ce qui arrange son détenteur. Chaque joueur doit annoncer le nombre de plis qu'il pense faire à chaque tour.

Pour trouver une bonne stratégie, Alice s'en remet aux statistiques. Pour cela, elle note les valeurs des cartes gagnantes à chaque pli :

18; 22; 21; 13 ; 21; 22; 20 ; 22; 17 ; 18 ; 21 ; 17; 20; 22; 21 ; 18; 13; 10

- Combien de plis y a-t-il eu ?
- Déterminer la moyenne de cette série statistique au dixième près, en justifiant la réponse.
- Ordonner cette série statistique.
- Déterminer, en justifiant :
 - Son étendue.
 - Sa médiane.
 - Son premier quartile.
 - Son troisième quartile.
 - Son écart interquartile.

Annexe F (Questionnaire sur la portée de l'hypothèse)

Le questionnaire est précédé d'une brève explication du problème. Le *modus tollens* est également appelé «contradiction interne» (en plus de son nom réel), et la preuve de la négation «contradiction externe», pour rendre les options plus abordables.

Question 1 :

1. Supposons que la Terre est plate.
2. Alors, on voit le Soleil à toute heure.
3. Or, on ne voit pas le Soleil à toute heure.
4. Par l'absurde, la Terre n'est pas plate.

Analyse : 9 réponses, dont 9 pour *modus tollens*, 0 pour preuve de la négation, et 0 pour auto-contradiction. 0 n'y voit pas de contradiction. 0 ne sait pas ou ne considère rien de toutes les autres options.

Question 2a :

1. Supposons que $1/3$ est décimal.
2. Alors, il existe n un entier naturel tel que 10^n est divisible par 3.
3. Or, il n'existe aucun entier naturel n tel que 10^n soit divisible par 3.
4. Par l'absurde, $1/3$ n'est pas décimal.

Analyse : 9 réponses, dont 5 pour *modus tollens*, 3 pour preuve de la négation, et 1 pour auto-contradiction. 0 n'y voit pas de contradiction. 0 ne sait pas ou ne considère rien de toutes les autres options.

Question 2b :

1. Supposons que $1/3$ est décimal.
2. Alors, il existe n un entier naturel tel que 10^n est divisible par 3.
3. Or, nous ne trouvons aucun entier naturel n tel que 10^n soit divisible par 3.
4. Par l'absurde, $1/3$ n'est pas décimal.

Analyse : 4 réponses, dont 1 pour *modus tollens*, 1 pour preuve de la négation, et 0 pour auto-contradiction. 2 n'y voient pas de contradiction. 0 ne sait pas ou ne considère rien de toutes les autres options.


Question 3 :

1. Supposons qu'un alien, K'aa, soit religieux et athée.
2. Alors, K'aa croit en Dieu.
3. Or, K'aa ne croit pas en Dieu.
4. Par l'absurde, K'aa ne peut pas être religieux et athée.

Analyse : 9 réponses, dont 1 pour *modus tollens*, 1 pour preuve de la négation, et 7 pour auto-contradiction. 0 n'y voit pas de contradiction. 0 ne sait pas ou ne considère rien de toutes les autres options.

Annexe G (Exemple de traitement de copie d'élève)

Prenons l'exemple de la copie de l'élève identifié par le numéro 6 :



On ajoute alors cette liste de listes, une pour chaque sous-exercice, contenant les propositions-élèves pour chacune, à notre liste `modules.etapes.a_posteriori` :

```
[  
  ["f(-2) ≤ 2", "0 > 1"],  
  ["2 ≤ 2", "f(-5) ≤ 2"],  
  ["f(-2) < 1", "0 < 1"],  
  ["f(1) ≥ 1", "1 > 1"]  
],
```

Dans le fichier `mistral.csv`, on a cette entête-ci pour préciser le nom du modèle, la température testée, et surtout quelles colonnes correspondent à quelle information dans son analyse des copies d'élèves :

```
1   Modèle;Température  
2   mistral:7b;0  
3   Numéro étudiant;Numéro exercice;Proposition étudiant;Proposition inférence;Concordance générée (en %)  
4   0;0;"f(-2) ≤ 2";"f(-2) ≤ 2";"f(-2) ≤ 2";50;13;0
```

Pour prendre l'exemple de la proposition "0 > 1" de notre élève numéroté 6, dans l'exercice numéroté 0, on a ces lignes de comparaison aux étapes identifiées dans l'analyse *a priori* :

```
215   6;0;"f(-2) ≤ 2";"1 > -2";0  
216   6;0;"0 > 1";"f ≥ -2 sur [0;1]";0  
217   6;0;"0 > 1";"f est décroissante sur [1;2]";0  
218   6;0;"0 > 1";"f(1) = 1";0  
219   6;0;"0 > 1";"f(2) = -5";0  
220   6;0;"0 > 1";"-5 < -2";0  
221   6;0;"0 > 1";"-2 < 1";50  
222   6;0;"0 > 1";"f(1) = 1";0  
223   6;0;"0 > 1";"1 > -2";50  
224   6;1;"2 ≤ 2";"1 est le maximum de f";0
```

AUTORISATION DE DIFFUSION

Je, soussigné(e) : Bali Alexandre

Agissant en l'absence de toute contrainte et en sachant qu'en dehors de l'obligation de déposer nos travaux, nous bénéficions de la liberté de permettre ou non leur diffusion, autorisons sans limitation de temps à diffuser les travaux pour le mémoire ou l'écrit professionnel que nous avons effectués pour le Master MEEF, dans les conditions suivantes :

Consultation sur place en bibliothèque : ☒ oui ☐ non

Diffusion en texte intégral sur le réseau Internet : ☒ oui ☐ non

Étant entendu que les éventuelles restrictions de diffusion de nos travaux ne s'étendent pas à leur signalement dans les catalogues des bibliothèques accessibles sur place ou par réseaux.

La présente autorisation de diffusion vaut également pour la reproduction limitée aux seules fins des diffusions ainsi définies.

Nous renonçons à toute rémunération pour les diffusions et reproductions effectuées dans les conditions précisées ci-dessus.

Bon pour accord,

À La Boisse, le 11 avril 2025

Signature de l'auteur(e)

